Rozbudowa projektu Systemy Multi-Agentowe LLM do Analizy Sprawozdań Finansowych

Emilia Jasińska, Wanessa Kurowska, Mateusz Ostaszewski

11 stycznia 2026

Streszczenie

Niniejszy dokument stanowi dokumentację projektu dotyczącego systemów wieloagentowych opartych na dużych modelach językowych (LLM) w kontekście analizy sprawozdań finansowych. Zawiera analizę literatury, opis zastanego stanu projektu oraz opis sposobu, w jaki został on rozbudowany, a także metodologię ewaluacji systemu.

1 Analiza literaturowa

1.1 FinDebate (Cai et al., 2025)

Artykuł *FinDebate: A Multi-Agent Debate Framework for Institutional-Level Financial Analysis* [CCZ+25] przedstawia kompleksowe rozwiązanie oparte na dużych modelach językowych (LLM), które symuluje pracę profesjonalnego zespołu analityków finansowych. Autorzy zauważają, że tradycyjne systemy oparte na pojedynczym modelu LLM mają ograniczoną zdolność do prowadzenia złożonej analizy finansowej — często brakuje im krytycznej oceny, umiejętności rozważenia alternatywnych hipotez oraz spójnej syntezy danych ilościowych i jakościowych. FinDebate rozwiązuje te problemy poprzez wprowadzenie zorganizowanego systemu agentów, którzy działają w sposób zbliżony do interdyscyplinarnego zespołu analityków w instytucji finansowej.

System składa się z dwóch warstw: warstwy analityków domenowych oraz warstwy koordynującej (debaty). W warstwie podstawowej działa pięciu specjalistycznych agentów: *Analityk wyników* (analizuje sprawozdania finansowe i oblicza wskaźniki takie jak marża operacyjna czy przepływy pieniężne), *Analityk rynku* (interpretuje dane makroekonomiczne i trendy branżowe), *Analityk sentymentu* (ocenia ton wypowiedzi zarządu, relacje inwestorskie i komunikaty prasowe), *Analityk wyceny* (stosuje modele wyceny, np. DCF, P/E, EV/EBITDA) oraz *Analityk ryzyka* (ocenia płynność, dźwignię finansową i czynniki ryzyka kredytowego). Każdy agent korzysta z własnych kontekstów promptów oraz może wyszukiwać dane w repozytorium wiedzy przy użyciu modułu **Retrieval-Augmented Generation (RAG)** opartego o bazę wektorową ChromaDB. Pozwala to na bezpośrednie odwoływanie się do źródeł, takich jak raporty 10-K, sprawozdania kwartalne czy wiadomości rynkowe.

Po zakończeniu indywidualnych analiz, system przechodzi do drugiej fazy: **debaty międzyagentowej (group chat)**. Uczestniczą w niej trzy meta-role: *Agent Zaufania*, który koncentruje się na wzmacnianiu i uzasadnianiu kluczowych argumentów w raporcie, dodając odniesienia do danych i źródeł; *Agent Sceptyk*, którego zadaniem jest krytyczna analiza — wskazywanie braków, nadmiernych uogólnień i potencjalnych błędów interpretacyjnych; oraz *Agent Lider*, pełniący funkcję moderatora, integrującego perspektywy pozostałych dwóch agentów w spójną i wiarygodną wersję końcową raportu.

Cały proces przebiega w sposób interaktywny — agenci wymieniają się wiadomościami w ramach wspólnego kanału konwersacji, reagując na argumenty i kontrargumenty pozostałych uczestników. Taki **tryb grupowej dyskusji** pozwala na wprowadzenie elementu *wewnętrznej weryfikacji* — poszczególne wnioski są poddawane krytyce i rewizji przed ostateczną publikacją. Debata kończy się wygenerowaniem syntetycznego raportu inwestycyjnego, który łączy dane ilościowe (wskaźniki finansowe) z interpretacją jakościową (ocena strategii zarządu, ryzyk rynkowych i nastroju inwestorów). FinDebate stanowi punkt odniesienia dla rozwoju naszego systemu — w szczególności poprzez zastosowanie **trybu współpracy typu group chat**, w którym agenci dyskutują i korygują swoje wnioski w czasie rzeczywistym.

1.2 Satapathy et al. (2025)

W pracy *Multi-Agent LLMs for Financial Report Analysis* [SCP+25] autorzy proponują lekką, lecz dobrze zorganizowaną architekturę trzech współpracujących agentów LLM, zaprojektowaną do półautomatycznej analizy raportów finansowych i transkryptów telekonferencji wynikowych. Celem systemu jest generowanie czytelnych i merytorycznie poprawnych raportów inwestycyjnych, które mogą wspomagać analityków w procesie podejmowania decyzji.

Architektura i przepływ informacji System opiera się na trzech rolach agentów, działających w modelu **sekwencyjnym (sequential pipeline)**:

- **Agent Analityk (Analyst)** odpowiada za ekstrakcję informacji z surowych danych wejściowych — głównie transkryptów konferencji wynikowych, raportów 10-K i danych liczbowych z bilansów. Wykorzystuje narzędzia do analizy tekstu oraz wbudowane zapytania do baz danych finansowych (np. API Yahoo Finance lub EDGAR), aby pozyskać fakty i liczby potrzebne do dalszej analizy. Jego zadaniem jest też wstępna klasyfikacja tonów wypowiedzi zarządu oraz identyfikacja fragmentów istotnych dla inwestorów (np. wzrost przychodów, czynniki ryzyka, zapowiedzi zmian strategii).
- **Agent Autor (Writer)** otrzymuje uporządkowany zbiór faktów od Analityka i na jego podstawie konstruuje narrację raportu inwestycyjnego. Tworzy logiczną strukturę tekstu, obejmującą streszczenie wyników, interpretację przyczyn zmian finansowych oraz ocenę przyszłych perspektyw spółki. Jego praca ma charakter kreatywny, ale musi pozostać wierna źródłowym danym — raport ma być zrozumiały, spójny i przydatny dla czytelnika.
- **Agent Redaktor (Editor)** pełni funkcję kontroli jakości i spójności. Analizuje treść raportu przygotowanego przez Autora, poprawia błędy logiczne, usuwa powtórzenia i ocenia, czy wnioski faktycznie wynikają z przytoczonych danych. Może również wprowadzać drobne korekty stylistyczne, aby raport był bardziej przejrzysty i profesjonalny. Redaktor nie dodaje nowych informacji – jego rola to *walidacja i standaryzacja* raportu końcowego.

Cały proces przebiega w sposób liniowy: dane przepływają od Analityka do Autora, a następnie do Redaktora. Nie występuje tu bezpośrednia komunikacja zwrotna (jak w FinDebate), ale poszczególne etapy są ściśle kontrolowane, co umożliwia łatwe śledzenie i ewaluację wpływu każdego agenta na końcowy wynik.

Model Satapathy et al. stanowi przykład skutecznej współpracy agentów w trybie **sequential**, gdzie każdy etap przetwarzania jest od siebie logicznie zależny i jasno określony. W naszym projekcie planujemy odtworzyć podobną strukturę sekwencyjną – od ekstrakcji danych po redakcję końcową – co pozwoli na ścisłą kontrolę przepływu informacji i ocenę jakości poszczególnych faz przetwarzania.

1.3 Xu et al. (2025)

W pracy *Emulating fundamental analysts: Analytical Stage-Based Multi-Agent Framework Enhanced with Expert Guidance and Preference-Anchored Likelihood Adjustment* [XPM+25] autorzy z Uniwersytetu Tokijskiego i Nomura Holdings prezentują wieloagentowe rozwiązanie oparte na dużych modelach językowych (LLM), które ma na celu odwzorowanie sposobu pracy analityków fundamentalnych w instytucjach finansowych. System został zaprojektowany tak, aby umożliwić modelom językowym prowadzenie wieloetapowej analizy sprawozdań finansowych i raportów wynikowych przedsiębiorstw w sposób przypominający rzeczywisty proces analityczny ludzi.

Architektura i przepływ informacji Proponowana architektura nosi nazwę **Analytical Stage-Based Multi-Agent Framework** i dzieli proces analizy fundamentalnej na trzy etapy (ang. *stages*), z których każdy realizowany jest przez dedykowanego agenta LLM.

- **Financial Analyzer** – pierwszy etap obejmuje ilościową analizę danych finansowych spółki. Agent ten oblicza kluczowe wskaźniki, takie jak tempo wzrostu przychodów i zysków, postęp względem prognoz, czy zmiany w polityce dywidend. Do promptów agenta dodawane jest tzw. *expert guidance* — opisy metod analizy używane przez profesjonalnych analityków — co umożliwia mu prowadzenie bardziej precyzyjnej i ustrukturyzowanej oceny finansów przedsiębiorstwa.

- **Business Analyzer** – drugi etap łączy wyniki ilościowe z etapu pierwszego z jakościowymi informacjami pochodzącymi z raportów kwartalnych i komunikatów spółek. Agent tworzy najpierw konspekt analizy, a następnie na jego podstawie generuje pełny opis kondycji biznesowej firmy, uwzględniając m.in. powody zmian wyników oraz politykę wobec akcjonariuszy. Tak jak poprzedni agent, korzysta on z ekspertowych wskazówek tekstowych, aby zapewnić spójność i kompletność raportu.

- **Conclusion Deriver** – końcowy etap odpowiada za identyfikację najważniejszych wniosków z poprzedniego etapu oraz ocenę przyszłych perspektyw spółki. Agent klasyfikuje ogólną kondycję jako „pozytywną" lub „negatywną", bazując na kluczowych czynnikach finansowych i jakościowych. Ponieważ proces ten wymaga wnioskowania trudnego do opisania w formie prostych reguł, autorzy zastosowali metodę **fine-tuningu** z wykorzystaniem własnej techniki **Preference-Anchored Likelihood Adjustment (PALA)**.

Przepływ informacji w systemie ma charakter **sekwencyjny**: dane finansowe są najpierw przetwarzane przez Financial Analyzer, następnie wyniki przekazywane są do Business Analyzer, który generuje rozszerzoną analizę jakościową, a ta z kolei trafia do Conclusion Deriver, gdzie formułowane są końcowe rekomendacje. Dzięki temu każdy agent pełni jasno zdefiniowaną funkcję i bazuje na rezultatach pracy poprzedniego, tworząc spójny łańcuch przetwarzania danych (*Stage 1* $\rightarrow$ *Stage 2* $\rightarrow$ *Stage 3*). Autorzy dodatkowo wprowadzają **Memory Base** – bazę wiedzy w formie grafu, w której zapisywane są wszystkie dane i wyniki analiz, co pozwala na ponowne wykorzystanie informacji w kolejnych analizach.

Model Xu et al. stanowi przykład zaawansowanego trybu współpracy typu **sequential**, w którym agenci pracują etapowo, przekazując wyniki między sobą. W przeciwieństwie do modeli typu *group chat* (np. FinDebate), tu nie występuje bezpośrednia wymiana wiadomości między agentami – współpraca odbywa się poprzez przekazywanie strukturalnych wyników między etapami. Takie podejście zapewnia większą kontrolę nad przepływem informacji i ułatwia ewaluację jakości poszczególnych faz analizy. W kontekście naszego projektu artykuł ten stanowi inspirację do dalszego rozwoju trybu **Sequential** i jego porównania z planowanym trybem **Group Chat**, przy zachowaniu modułowej struktury analitycznej i etapowego przetwarzania danych.

1.4 Xiao et al. (2025)

Artykuł *TradingAgents: Multi-Agents LLM Financial Trading Framework* [XSLW25] przedstawia rozbudowaną architekturę wieloagentową opartą na dużych modelach językowych (LLM), zaprojektowaną do kompleksowej analizy rynków finansowych oraz wspomagania decyzji inwestycyjnych. Autorzy wskazują, że tradycyjne podejścia oparte na pojedynczym modelu LLM mają ograniczoną zdolność do prowadzenia pełnej analizy finansowej — zwłaszcza w kontekście integracji danych ilościowych (sprawozdań finansowych, wskaźników rynkowych) i jakościowych (komunikaty prasowe, sentyment inwestorów). Proponowany system łączy więc różne typy agentów, z których każdy odpowiada za określoną dziedzinę analizy, a ich współpraca odbywa się w trybach równoległym, sekwencyjnym i debatowym.

Architektura i przepływ informacji System **TradingAgents** składa się z kilku warstw funkcjonalnych, które emulują pracę rzeczywistego zespołu analityków w instytucji finansowej. Podstawowy zespół analityczny (*Analyst Team*) obejmuje czterech specjalistycznych agentów:

- **Fundamental Analyst** – analizuje dane ze *sprawozdań finansowych* (m.in. raportów 10-K i 10-Q), obliczając kluczowe wskaźniki takie jak P/E, ROE, marża zysku czy poziom zadłużenia. Agent ten ocenia kondycję finansową spółki, uwzględniając zmiany przychodów, kosztów i przepływów pieniężnych.

- **News Analyst** – przetwarza wiadomości branżowe, komunikaty prasowe i raporty kwartalne, identyfikując zdarzenia mogące wpływać na wyniki finansowe i wycenę spółki. Łączy dane faktograficzne z oceną wpływu rynkowego.

- **Sentiment Analyst** – analizuje dane z mediów społecznościowych i forów inwestorskich (np. Reddit, X/Twitter), określając nastroje inwestorów wobec danej spółki lub sektora. Wykorzystuje modele LLM do klasyfikacji sentymentu i wykrywania zmian trendów.

- **Technical Analyst** – interpretuje dane rynkowe, wykresy cenowe i wskaźniki techniczne (np. RSI, MACD, Bollinger Bands), generując krótkoterminowe sygnały kupna i sprzedaży.

Agenci zespołu analitycznego działają **równolegle (parallel/concurrent)** — każdy niezależnie analizuje przypisaną kategorię danych i przekazuje swoje wyniki do wspólnego repozytorium wiedzy. Po zakończeniu tej fazy uruchamiany jest drugi poziom systemu — **Researcher Team**, w którym odbywa się **debatowy tryb współpracy (group chat)**. W tej fazie agenci o przeciwstawnych perspektywach — tzw. *bullish researcher* i *bearish researcher* — prowadzą kontrolowaną dyskusję nad interpretacją wyników, wskazując kluczowe argumenty „za" i „przeciw" inwestycji w analizowaną spółkę. Debatę moderuje *Chief Researcher*, który pełni funkcję mediatora i integratora wniosków, generując końcowy raport analityczny.

W trzeciej warstwie, wyniki analizy przekazywane są do agentów decyzyjnych:

- **Trader** – generuje decyzje inwestycyjne (kupno/sprzedaż/utrzymanie pozycji) na podstawie raportu badawczego.
- **Risk Management Agent** – weryfikuje decyzję tradera, oceniając potencjalne ryzyko transakcji, a następnie dostosowuje strategię do poziomu ryzyka portfela inwestycyjnego.

Przepływ informacji w systemie ma charakter **hybrydowy**: analiza ilościowa i jakościowa przebiega równolegle, następnie wyniki są syntetyzowane w ramach grupowej debaty badaczy, po której następuje sekwencyjne przekazanie raportu do modułów decyzyjnych. Takie połączenie trybów współpracy pozwala na uzyskanie spójnych i wieloaspektowych rekomendacji inwestycyjnych.

Model **TradingAgents** stanowi przykład wieloagentowego systemu, który łączy różne tryby współpracy: równoległy (dla analizy danych), debatowy (dla interpretacji wyników) i sekwencyjny (dla generowania decyzji). W przeciwieństwie do systemów typowo sekwencyjnych, takich jak *Satapathy et al. (2025)*, tutaj zastosowano bardziej dynamiczną formę interakcji agentów, zbliżoną do pracy zespołu analityków inwestycyjnych w rzeczywistych instytucjach finansowych. W kontekście naszego projektu, artykuł ten stanowi inspirację dla wdrożenia hybrydowego trybu współpracy agentów — łączącego zalety równoległego przetwarzania danych z kontrolowaną dyskusją w stylu **group chat**.

1.5 Kim et al. (2025)

Praca *Financial Statement Analysis with Large Language Models* [KMN25] bada, czy duże modele językowe mogą wykonywać analizę sprawozdań finansowych na poziomie porównywalnym z profesjonalnymi analitykami finansowymi. Autorzy koncentrują się na tym, czy GPT-4 jest w stanie – na podstawie wyłącznie zanonimizowanych i wystandaryzowanych danych liczbowych z rachunku zysków i strat oraz bilansu – przewidzieć kierunek przyszłych wyników finansowych przedsiębiorstwa, tj. czy zysk netto wzrośnie lub spadnie w następnym okresie.

W badaniu wykorzystano dane dla 150 678 firmolat z lat 1968–2021, w pełni pozbawione informacji identyfikujących spółkę, co uniemożliwia modelowi odwołanie się do pamięci treningowej. Autorzy projektują dwa typy promptów: prosty (polecenie analizy i prognozy) oraz rozbudowany, oparty na chain-of-thought, który imituje sposób pracy analityków – identyfikację trendów, wyliczenie kluczowych wskaźników finansowych oraz interpretację zmian. Wyniki pokazują, że prosty prompt pozwala modelowi osiągnąć jedynie przeciętne rezultaty, natomiast zastosowanie chain-of-thought prowadzi do znacznej poprawy skuteczności.

Model GPT-4 Turbo osiąga 60% trafności co przewyższa analityków finansowych, których trafność w pierwszym miesiącu po publikacji sprawozdań wynosi ok. 53%, a nawet po 6 miesiącach nie przekracza 56–57%. Autorzy dowodzą również, że przewaga LLM jest szczególnie widoczna w sytuacjach, w których analitycy często popełniają błędy, m.in. w przypadku małych spółek, o wysokiej zmienności wyników czy generujących straty.

W artykule porównano także wyniki GPT z wynikami wąsko trenowanych modeli uczenia maszynowego (logistyczna regresja oraz ANN). Z porównania wynika, że GPT osiąga bardzo zbliżone – a czasami wyższe – rezultaty niż sztuczne sieci neuronowe trenowane na dziesiątkach zmiennych fundamentalnych, mimo braku specjalistycznego treningu finansowego po stronie LLM. Autorzy potwierdzają, że skuteczność GPT nie wynika z pamięci modelu ani znajomości danych historycznych, jako że model nie potrafi odgadnąć nazwy firmy ani roku na podstawie danych liczbowych.

Badanie dostarcza silnych dowodów na to, że LLM-y mogą skutecznie analizować sprawozdania finansowe oraz generować trafne i interpretowalne wnioski wyłącznie na podstawie danych

liczbowych, co dotychczas było uznawane za wymagające intuicji i wiedzy eksperckiej. Artykuł podkreśla, że rozbudowane podejście chain-of-thought znacząco zwiększa zdolności modelu i umożliwia mu generowanie wartościowych wniosków bez dostępu do narracji czy kontekstu branżowego.

1.6 Guo et al. (2024)

Artykuł *Large Language Model-based Multi-Agents: A Survey of Progress and Challenges* [GCW+24] przedstawia kompleksowy przegląd współczesnych systemów multi-agentowych opartych na dużych modelach językowych (LLM-MA). Autorzy analizują ewolucję systemów składających się z pojedynczego agenta do złożonych środowisk współpracy wielu agentów, w których LLM-y pełnią wyspecjalizowane role i komunikują się między sobą w celu rozwiązywania problemów o większej złożoności.

W artykule wyróżniono cztery kluczowe obszary konstrukcji systemów multi-agentowych:

- **Interfejs agent–środowisko (Agents-Environment Interface)** – Autorzy przedstawiają trzy typy środowisk, w których funkcjonują obecnie LLM-MA: sandbox, physical i none. Podkreślają, że w zależności od typu zadania, środowisko może pełnić rolę przestrzeni symulacyjnej, rzeczywistej lub być całkowicie pomijalne (np. w debatach agentów).
- **Profilowanie agentów (Agent Profiling)** – Istotnym elementem architektury multi-agentowej jest przypisanie agentom ról, kompetencji i ograniczeń, co może być realizowane poprzez profile predefiniowane, generowane przez modele lub oparte na danych. Pozwala to na tworzenie zespołów wyspecjalizowanych agentów, którzy lepiej rozwiązują złożone zadania poprzez podział kompetencji.
- **Komunikacja między agentami (Agent Communication)** – Autorzy prezentują trzy główne wzorce interakcji: cooperative, debate oraz competitive. Omawiają również struktury komunikacyjne (centralized, decentralized, layered, shared-pool), a zwłaszcza ich wpływ na przepływ informacji, zdolność osiągania konsensusu oraz efektywność zespołu agentów.
- **Nabywanie i rozwój kompetencji (Agent Capability Acquisition)** – W artykule opisano sposoby zwiększania zdolności agentów, takie jak: wykorzystanie pamięci (memory retrieval), procesy samo-ewolucyjne (self-evolution), adaptacja przez komunikację (Learning Through Communication), a także dynamiczna generacja nowych agentów. Szczególny nacisk nałożono na mechanizmy sprzężenia zwrotnego – zarówno z otoczenia, jak i od innych agentów.

Autorzy przedstawiają również szeroki przegląd zastosowań LLM-MA — od rozwiązywania problemów (software development, robotyka, debata naukowa) po symulacje społeczne, ekonomiczne i psychologiczne. Wskazują na szybko rosnące zainteresowanie agentami LLM w zadaniach wymagających kolektywnej inteligencji i symulacji zachowań ludzkich.

W końcowych częściach artykułu omówiono kluczowe wyzwania stojące przed systemami multi-agentowymi, m.in. problem halucynacji i propagacji błędów między agentami, trudności w skalowaniu (orkiestracja), brak standaryzowanych benchmarków oraz brak środowisk multimodalnych umożliwiających pełniejsze wykorzystanie możliwości LLM.

Publikacja stanowi przekrojowe, uporządkowane spojrzenie na obecny stan badań nad systemami multi-agentowymi oraz wyznacza kierunki przyszłych prac nad efektywnym projektowaniem i ewaluacją zespołów agentów opartych na LLM. Artykuł jest kluczowy do realizacji naszego projektu, ponieważ omawia fundamenty architektury multi-agentowej, modele komunikacji oraz wyzwania ewaluacyjne, które bezpośrednio odpowiadają problematyce rozwijania i oceniania systemów LLM współpracujących w ramach zadań analitycznych.

2 Pierwotny stan projektu

Aktualna wersja projektu, zatytułowana *Stock Investment Analysis Platform*, jest aplikacją do analizy inwestycyjnej akcji zbudowaną w oparciu o framework **CrewAI** oraz modele **Google Gemini**. System funkcjonuje jako platforma wieloagentowa, w której każdy agent odpowiada za inny aspekt analizy finansowej. Całość obsługiwana jest przez interfejs webowy w **Streamlit**, umożliwiający

użytkownikowi podanie symbolu giełdowego i uzyskanie szczegółowego raportu inwestycyjnego w formacie Markdown.

W skład zespołu agentów wchodzą obecnie:

- **Senior Stock Market Researcher** – gromadzi dane jakościowe i informacje z mediów (Yahoo Finance, Reddit, Yahoo News), przeprowadzając analizę sentymentu publicznego,
- **Expert Technical Analyst** – dokonuje analizy technicznej kursu akcji z użyciem wskaźników TA-Lib (m.in. RSI, MACD, Bollinger Bands),
- **Senior Fundamental Analyst** – analizuje dane fundamentalne (P/E, P/S, D/E, ROE) oraz kondycję finansową spółki,
- **Chief Investment Strategist (Reporter)** – łączy wnioski pozostałych agentów w końcowy raport inwestycyjny.

Architektura systemu ma charakter **sekwencyjny (sequential)** — wyniki pracy poszczególnych agentów są przekazywane w ustalonej kolejności do raportera, który generuje końcowy dokument. Każdy agent jest definiowany w pliku `agents.py` poprzez klasę CrewAI z przypisanym zadaniem (promptem) i rolą, a ich współpraca odbywa się poprzez centralny koordynator (`StockAnalysisCrew`). System wykorzystuje dane z Yahoo Finance, Reddita oraz własne modele sentymentu oparte na Transformers, łącząc elementy analizy ilościowej i jakościowej.

3 Rozbudowa projektu

Rozbudowaliśmy projekt dodając następujące komponenty:

3.1 Tryb współpracy typu Group Chat (inspirowany FinDebate)

Pierwotnie agenci działali w sposób liniowy, bez bezpośredniej interakcji. W nowej wersji wprowadziliśmy tryb **group chat**, w którym agenci mogą prowadzić kontrolowaną dyskusję nad raportem, wymieniając opinie i argumenty. Całość moderowana jest przez specjalnego agenta typu *leader*.

Dzięki temu możliwe jest uzyskanie bardziej spójnych i krytycznie zweryfikowanych analiz, zbliżonych do rzeczywistego procesu decyzyjnego w zespołach analitycznych.

W trybie tym pojawiły się nowe role inspirowane architekturą FinDebate:

- **Agent Sceptyk** – wskazuje nieścisłości, błędne założenia lub potencjalne ryzyka w analizie,
- **Agent Zaufania** – weryfikuje poprawność danych oraz uzasadnień w oparciu o dostępne źródła,
- **Agent Lider** – moderuje dyskusję i integruje argumenty pozostałych agentów w finalny raport.

Komunikacja agentów odbywa się w ramach wspólnego kanału rozmowy (*shared chat space*), co umożliwia wprowadzenie elementu debaty i wzajemnej weryfikacji, zbliżonego do procesu pracy zespołu analityków finansowych w instytucjach inwestycyjnych.

3.2 Zachowanie trybu Sequential (inspirowanego Satapathy et al.)

Dotychczasowy tryb sekwencyjny został utrzymany jako punkt odniesienia dla porównań eksperymentalnych. Dzięki temu możliwe jest przeprowadzenie badań porównawczych pomiędzy trybami **Sequential** oraz **Group Chat**, w celu oceny jakości generowanych raportów, spójności wniosków oraz efektywności obliczeniowej.

W obu przypadkach wykorzystywane są te same źródła danych oraz modele językowe, co umożliwia obiektywną ewaluację uzyskiwanych wyników.

3.3 Integracja dodatkowego providera LLM

W ramach rozbudowy systemu zintegrowano kolejnego dostawcę modeli językowych **OpenAI**. Dzięki temu użytkownik otrzymuje możliwość wyboru providera LLM wykorzystywanego do analizy danych, prowadzenia dyskusji agentów oraz generowania raportów końcowych.

Takie podejście zwiększa elastyczność systemu, umożliwia porównywanie jakości odpowiedzi różnych modeli oraz pozwala lepiej dostosować działanie platformy do indywidualnych potrzeb użytkownika lub ograniczeń obliczeniowych.

3.4 Dodatkowe źródła danych

Zmiana źródeł danych sentymentowych (Reddit → Finnhub i Alpha Vantage)

W pierwotnej wersji systemu, stanowiącej punkt wyjścia niniejszego projektu, analiza sentymentu oraz nastrojów rynkowych opierała się na danych pozyskiwanych z wykorzystaniem **Reddit API**. Źródło to umożliwiało analizę opinii inwestorów indywidualnych oraz identyfikację trendów dyskusyjnych wokół wybranych instrumentów finansowych. Rozwiązanie to było adekwatne i funkcjonalne na etapie powstawania bazowej implementacji systemu.

W trakcie realizacji projektu ujawniono jednak istotne ograniczenia techniczne, które były niezależne od zespołu projektowego. Od momentu opracowania pierwotnej wersji systemu, serwis Reddit wprowadził znaczące zmiany w polityce dostępu do swojego interfejsu programistycznego. W szczególności, **nie jest obecnie możliwe generowanie nowych kluczy Reddit API** dla standardowych zastosowań badawczych, co uniemożliwiło dalsze korzystanie z tego źródła danych oraz pełne odtworzenie funkcjonalności systemu w aktualnym środowisku projektowym.

W związku z powyższym podjęto decyzję o **zastąpieniu Reddit API stabilnymi i profesjonalnymi źródłami danych finansowych**, tj. **Finnhub API** oraz **Alpha Vantage API**. Wybór tych rozwiązań był podyktowany następującymi przesłankami:

- gwarantowanym oraz oficjalnie udokumentowanym dostępem do interfejsów API,
- stabilnością i długoterminowym wsparciem oferowanych usług,
- jasno określonymi warunkami użytkowania, odpowiednimi dla celów badawczych,
- możliwością pozyskiwania ustrukturyzowanych danych rynkowych, fundamentalnych oraz wskaźników technicznych.

Zastosowanie nowych źródeł danych wymagało odpowiedniej adaptacji warstwy integracyjnej systemu, jednak nie wpłynęło negatywnie na jego ogólną architekturę. Zmiana ta miała charakter **koniecznej adaptacji infrastrukturalnej**, wynikającej z ewolucji zewnętrznych usług, a nie z błędów koncepcyjnych pierwotnego rozwiązania.

W efekcie przeprowadzonej rozbudowy możliwe było przywrócenie pełnej funkcjonalności agenta *Senior Stock Market Researcher*, zwiększenie wiarygodności oraz jakości danych wejściowych, a także dalsza realizacja eksperymentów badawczych w sposób powtarzalny, kontrolowany i zgodny z aktualnymi ograniczeniami technologicznymi.

3.5 Dodatkowe funkcjonalności platformy

W ramach rozbudowy systemu wdrożono już istotne funkcjonalne ulepszenia, które znacząco zwiększają użyteczność i elastyczność platformy analitycznej. Zrealizowane prace obejmują:

3.5.1 Rozszerzenie zestawu wskaźników technicznych

Wskaźniki dodatkowych miar zmienności oraz dynamiki cen mogą być konfigurowane przez użytkownika w interfejsie aplikacji oraz bezpośrednio wykorzystywane do **tworzenia i analizy wykresów**.

Na rysunku 1 przedstawiono cztery przykładowe konfiguracje wykresów cenowych, ilustrujące elastyczność systemu w zakresie doboru typu wykresu oraz wskaźników technicznych:

- wykres świecowy z pełnym zestawem średnich kroczących SMA,
- wykres świecowy z wykorzystaniem średnich wykładniczych EMA,
- wykres świecowy z nałożonymi wstęgami Bollingera,
- wykres liniowy z wstęgami Bollingera jako alternatywa dla wizualizacji świecowej.



(a) Wykres świecowy z średnimi kroczącymi SMA (SMA 20, SMA 50, SMA 200)



(b) Wykres świecowy z średnimi wykładniczymi EMA (EMA 20, EMA 50)



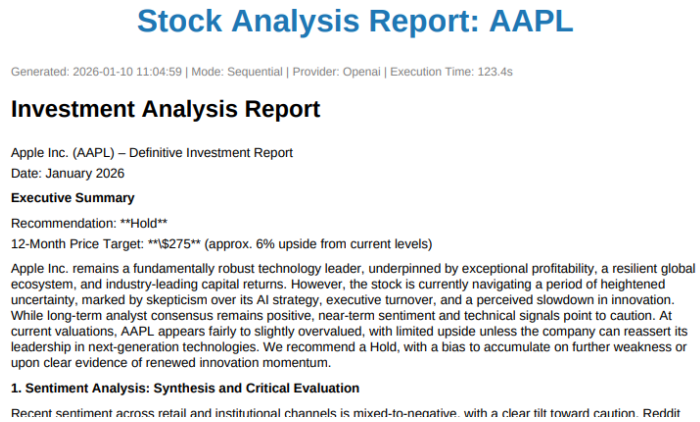
(c) Wykres świecowy z wstęgami Bollingera



(d) Wykres liniowy z wstęgami Bollingera

Rysunek 1: Cztery przykładowe konfiguracje wykresów technicznych dostępnych w aplikacji

---



Stock Analysis Report: AAPL

Generated: 2026-01-10 11:04:59 | Mode: Sequential | Provider: Openai | Execution Time: 123.4s

Investment Analysis Report

Apple Inc. (AAPL) – Definitive Investment Report

Date: January 2026

Executive Summary

Recommendation: **Hold**

12-Month Price Target: **\$275** (approx. 6% upside from current levels)

Apple Inc. remains a fundamentally robust technology leader, underpinned by exceptional profitability, a resilient global ecosystem, and industry-leading capital returns. However, the stock is currently navigating a period of heightened uncertainty, marked by skepticism over its AI strategy, executive turnover, and a perceived slowdown in innovation. While long-term analyst consensus remains positive, near-term sentiment and technical signals point to caution. At current valuations, AAPL appears fairly to slightly overvalued, with limited upside unless the company can reassert its leadership in next-generation technologies. We recommend a Hold, with a bias to accumulate on further weakness or upon clear evidence of renewed innovation momentum.

1. Sentiment Analysis: Synthesis and Critical Evaluation

Recent sentiment across retail and institutional channels is mixed-to-negative, with a clear tilt toward caution. Reddit

Rysunek 2: Fragment przykładowego raportu analityczny wygenerowany w formacie PDF

3.5.2 Dodanie funkcji eksportu raportów do formatu PDF

Funkcja eksportu raportów do formatu PDF obejmuje zarówno analizy tekstowe generowane przez agentów, jak i wygenerowane wykresy oraz zestawienia wskaźników technicznych. Umożliwia to tworzenie kompletnych, uporządkowanych raportów analitycznych w postaci jednego dokumentu.

Funkcjonalność ta ułatwia archiwizację wyników analizy oraz ich dalsze wykorzystanie w kontekście instytucjonalnym, np. w raportach wewnętrznych, dokumentacji projektowej lub materiałach wspierających procesy decyzyjne.

Na rysunku 2 przedstawiono fragment przykładowego raportu wygenerowanego automatycznie przez system w formacie PDF, zawierający podsumowanie analizy, wykresy cenowe oraz wybrane wskaźniki techniczne.

4 Eksperymenty i ewaluacja

Niniejsza sekcja przedstawia planowaną metodologię badawczą oraz proponowane metryki oceny, które zostaną w pełni wdrożone w kolejnym etapie projektu.

4.1 Tryby współpracy agentów

System został rozbudowany o dwa różne tryby współpracy wieloagentowej:

- **Sequential (Sekwencyjny)** - tryb oryginalny, w którym agencji pracują w ustalonej kolejności: Researcher → Technical Analyst → Fundamental Analyst → Reporter. Każdy agent przekazuje wyniki swojej analizy kolejnemu w łańcuchu, aż do wygenerowania końcowego raportu przez Chief Investment Stategist.
- **Group Chat (FinDebate)** - nowy tryb inspirowany architekturą FinDebate [CCZ+25], w którym po fazie analizy specjalistycznej (Researcher, Technical Analyst. Fundamental Analyst) następuje faza debaty międzyagentowej moderowana przez Leader Agent. W debacie uczestniczą również Sceptic Agent (wskazujący ryzyka i słabe punkty argumentacji) oraz Trust Agent (weryfikujący wiarygodność danych i źródeł).

Oba tryby wykorzystują te same narzędzia analityczne (Yahoo Finance API, Finnhub API, Alpha Vantage API, TA-Lib) oraz modele językowe OpenAI (GPT-4o-mini dla Sequential, GPT-4o dla Group Chat), co pozwala na bezpośrednie jakości wyników w zależności od struktury przepływu informacji między agentami.

4.2 Metryki ewaluacji

W celu obiektywnej oceny jakości raportów inwestycyjnych generowanych przez system zaprojektowaliśmy i zaimplementowaliśmy kompletny system automatycznej ewaluacji. System został zrealizowany w języku Python jako moduł `src/utils/report_evaluator.py` i umożliwia pełną automatyzację procesu oceny raportów bez konieczności manualnej interwencji. Ewaluacja opiera się na 5 wymiarach jakości, które łącznie obejmują zarówno aspekty merytoryczne, jak i techniczne.

4.2.1 Architektura systemu ewaluacji

System ewaluacji zaimplementowany w klasie `ReportEvaluator` składa się z następujących komponentów:

- **Moduł ekstrakcji danych** - automatycznie identyfikuje i ekstrahuje z raportu dane liczbowe, wskaźniki finansowe (P/E, RSI, MACD, etc.) oraz cytowania źródeł za pomocą wyrażeń regularnych.
- **Moduł analizy struktury** - weryfikuje obecność wymaganych sekcji oraz zlicza elementy strukturalne (nagłówki, pogrubienia i paragrafy).
- **Moduł analizy profesjonalizmu języka** - implementuje odwrócony algorytm Flesch Reading Ease do pomiaru wyrafinowania językowego tekstu na podstawie długości zdań i liczby sylab w słowach.
- **Moduł analizy sentymentu** - wykorzystuje słowniki słów pozytywnych i negatywnych charakterystycznych dla języka finansowego (po 16 słów każdy) do obliczenia balansu sentymentu raportu.
- **Moduł oceny użyteczności** - weryfikuje obecność konkretnych rekomendacji inwestycyjnych (Buy/Sell/Hold), cen docelowych oraz horyzontów czasowych.
- **Agregator wyników** - łączy wyniki wszystkich powyższych modułów w ostateczny wynik jakości według ustalonej formuły wagowej, przypisując każdemu wymiarowi wagę odzwierciedlającą jego znaczenie dla wartości merytorycznej raportu.

4.2.2 Zaimplementowane metryki

System ewaluacji obejmuje 5 kluczowych wymiarów jakości, z których każdy mierzy inny aspekt wartości raportu inwestycyjnego.

1. Struktura dokumentu (waga: 25%) Metryka ocenia **kompletność i organizację** raportu poprzez weryfikację obecności 8 wymaganych sekcji oraz analizę elementów strukturalnych.

Wymagane sekcje:

- Executive Summary (Streszczenie wykonawcze)
- Sentiment Analysis (Analiza sentymentu z uzasadnieniem)
- Technical Analysis (Analiza techniczna ze wskaźnikami)
- Fundamental Analysis (Analiza fundamentalna z metrykami finansowymi)
- Risk Assessment (Ocena ryzyka i czynników zagrożeń)
- Convergences/Divergences (Zbieżności i rozbieżności między analizami)
- Catalysts (Katalizatory wzrostu lub spadku)
- Final Recommendation (Końcowa rekomendacja inwestycyjna: Buy/Sell/Hold)

System zlicza liczbę nagłówków w dwóch formatach: nagłówki Markdown (linie rozpoczynające się od `#`, `##`, `###`) oraz pogrubienia na początku linii (`**Nazwa sekcji**`), co umożliwia rozpoznawanie różnych konwencji formatowania stosowanych przez agentów LLM. Dodatkowo zliczane są paragrafy (bloki tekstu oddzielone pustymi liniami). Wynik struktury (S) obliczany jest według wzoru:

$$S = \left(0.6 \times \frac{\text{sekcje_znalezione}}{8} + 0.2 \times \min\left(\frac{\text{nagłówki}}{10}, 1\right) + 0.2 \times \min\left(\frac{\text{paragrafy}}{15}, 1\right)\right) \times 100 \tag{1}$$

gdzie wartości 10 i 15 stanowią progi odniesienia odpowiednio dla liczby nagłówków i paragrafów w dobrze ustrukturyzowanym raporcie. Dominujący wpływ kompletności sekcji (60%) odzwierciedla jej kluczowe znaczenie dla wartości merytorycznej raportu.

Źródło metryki

Dobór metryk strukturalnych inspirowany jest podejściami powszechnie stosowanymi w ewaluacji systemów generujących długie dokumenty oraz raporty analityczne. Kryteria takie jak pokrycie wymaganych sekcji tematycznych, obecność wyraźnych nagłówków oraz segmentacja treści na paragrafy pozwalają w sposób automatyczny ocenić organizację i czytelność raportu. Lista wymaganych sekcji została przyjęta zgodnie z architekturą raportów wypracowaną na wcześniejszym etapie projektu przez poprzednią grupę realizującą jego bazową wersję i stanowiła punkt odniesienia dla dalszej rozbudowy oraz formalizacji systemu ewaluacji.

Wykrywanie sekcji odbywa się za pomocą wyrażeń regularnych w języku Python, które wyszukują:

- Nagłówki Markdown w formacie `#`, `##`, `###`
- Pogrubienia na początku linii w formacie `**Nazwa sekcji**`
- Nazwy sekcji bez względu na wielkość liter (case-insensitive matching)

Implementacja jest w pełni autorska, oparta na module `re` z biblioteki standardowej Python, bez użycia zewnętrznych pakietów do parsowania dokumentów.

2. Bogactwo danych (waga: 25%) Metryka mierzy **ilość, różnorodność i gęstość** danych ilościowych zawartych w raporcie, co bezpośrednio przekłada się na jego wartość informacyjną:

- Liczby całkowite i zmiennoprzecinkowe (np. “237.50”, “15”)
- Wartości procentowe (np. “12.5%”)
- Kwoty w dolarach (np. “$250M”, “$1.2B”)
- Daty (formaty YYYY-MM-DD oraz tekstowe, np. “January 15, 2025”)

- **Wskaźniki finansowe** - zestaw kluczowych metryk analizy finansowej wykorzystywanych do oceny bogactwa merytorycznego raportu. Rozszerzony zbiór obejmuje **38 metryk w 8 kategoriach**, dobranych spośród powszechnie stosowanej terminologii analizy finansowej.
  - *Valuation Ratios* (6): P/E, Price/Earnings, P/S, Price-to-Sales, P/B, Price-to-Book
  - *Profitability Metrics* (10): EPS, ROE, ROA, ROI, EBITDA, EBIT, Profit Margin, Operating Margin, Gross Margin, Net Margin
  - *Growth Metrics* (8): Revenue, Revenue Growth, Earnings Growth, EPS Growth, Year-over-Year, YoY, QoQ, Quarter-over-Quarter
  - *Financial Health* (8): Debt-to-Equity, D/E, Current Ratio, Total Debt, Cash Flow, Free Cash Flow, FCF, Operating Cash Flow
  - *Market Metrics* (3): Market Cap, Market Capitalization, Volume
  - *Dividend Metrics* (3): Dividend, Dividend Yield, Dividend Growth
  - *Technical Indicators* (6): RSI, MACD, SMA, Moving Average, EMA, Exponential Moving Average
  - *Other* (7): Beta, Volatility, Analysts, Target Price, Price Target, Rating, Recommendation
- **Cytowania źródeł** - rozszerzone wzorce wykrywania odniesień:
  - Klasyczne: "according to", "source:", "based on", "reported by"
  - Finansowe: "analysts say", "analysts project", "analysts estimate"
  - Źródła danych: "yahoo finance", "reddit", "analyst", "data shows", "research indicates"
- **Gęstość danych** (ρ_d): stosunek wszystkich elementów danych (liczby + daty + cytowania) do liczby słów w raporcie

Wykrywanie wskaźników finansowych odbywa się w sposób *case-insensitive*, co pozwala na rozpoznawanie różnych wariantów zapisu (np. "P/E", "p/e", "Price/Earnings"). Duplikaty są automatycznie usuwane z listy znalezionych metryk.

Wynik bogactwa danych (D) normalizowany jest do skali 0-100 według wzoru:

$$D = \min\left(100, 0.5 \times n_{\text{liczby}} + 3 \times n_{\text{wskaźniki}} + 8 \times n_{\text{cytowania}}\right) \tag{2}$$

gdzie współczynniki wag (0.5, 3, 8) odzwierciedlają względne znaczenie poszczególnych typów danych dla wartości merytorycznej raportu. W porównaniu do pierwotnej wersji formuły, wagi zostały dostosowane aby uwzględnić znacznie rozszerzoną listę wskaźników (z 14 do 75) oraz dostosowanie kryteriów oceny do możliwości LLM. Wysoka waga cytowań (8×) podkreśla znaczenie wiarygodności źródeł w analizie finansowej.

Źródło metryki

Koncepcja pomiaru gęstości informacji (*information density*) w dokumentach finansowych pochodzi z prac nad analizą tekstualną Loughran & McDonald [LM16], gdzie wykazano, że ilość i różnorodność danych liczbowych oraz odniesień do źródeł jest kluczowym wskaźnikiem wartości informacyjnej dokumentu.

Lista 75 wskaźników finansowych została skompilowana na podstawie:

- Standardów CFA Institute [CFA23] - wskaźniki fundamentalne (P/E, ROE, ROA, etc.)
- Słownika terminów finansowych Investopedia [Inv25] - definicje oraz nazewnictwo wskaźników

Wzorce wykrywania cytowań zostały rozszerzone w stosunku do standardowych wzorców akademickich o frazy charakterystyczne dla języka finansowego ("analysts say", "data shows", "according to"), co zwiększa czułość detekcji w kontekście raportów inwestycyjnych.

Implementacja wykorzystuje:

- Wyrażenia regularne (`re`) - detekcja liczb, dat, kwot w USD

- Case-insensitive string matching - wykrywanie wskaźników finansowych w różnych formatach zapisu
- Algorytm usuwania duplikatów - zapobieganie wielokrotnemu liczeniu tej samej metryki

Cała implementacja jest autorska, bez użycia gotowych bibliotek do ekstrakcji danych finansowych.

3. Profesjonalizm języka (waga: 20%) System wykorzystuje odwrócony wskaźnik Flesch Reading Ease (F) do oceny wyrafinowania i profesjonalizmu języka raportu:

$$F = 206.835 - 1.015 \times \frac{\text{słowa}}{\text{zdania}} - 84.6 \times \frac{\text{sylaby}}{\text{słowa}} \tag{3}$$

Następnie obliczany jest wskaźnik *Professional Sophistication* (S_{prof}):

$$S_{\text{prof}} = 100 - F \tag{4}$$

W pierwotnej wersji wynik F oznacza prostszy tekst. Odwrócenie skali sprawia, że **wyższy wynik S_{prof} oznacza bardziej zaawansowany, akademicki język**, co jest pożądane w profesjonalnych raportach finansowych.

Wynik jest interpretowany według następującej skali:

- 70-100: *Highly Professional* (język akademicki/ekspercki) - doskonały poziom dla raportów
- 50-70: *Professional* (poziom uniwersytecki) - docelowy zakres dla raportów inwestycyjnych
- 40-50: *Semi-Professional* (poziom średniej szkoły wyższej) - akceptowalny, ale można poprawić
- 20-40: *Conversational* (język potoczny) - zbyt prosty dla profesjonalnego raportu
- 0-20: *Very Simple* (podstawowy poziom) - nieodpowiedni dla profesjonalnych raportów

Dla raportów inwestycyjnych skierowanych do analityków i inwestorów instytucjonalnych **optymalny wynik mieści się w przedziale 50-70**, co zapewnia profesjonalny, akademicki styl z zachowaniem zrozumiałości dla wykształconych odbiorców.

System dodatkowo zwraca w metrykach oryginalny wynik Flesch (dla referencji), liczbę zdań, słów, sylab oraz średnią liczbę słów na zdanie i sylab na słowo.

Źródło metryki

Wskaźnik Flesch Reading Ease został opracowany przez Rudolfa Flescha [Fle48] i jest jednym z najczęściej stosowanych narzędzi oceny czytelności tekstów. Odwrócenie skali (100 - F) w celu pomiaru profesjonalizmu języka jest powszechną praktyką w analizie dokumentów technicznych i finansowych, gdzie wyższa złożoność językowa koreluje z percepcją profesjonalizmu [LLM11].

Implementacja wykorzystuje standardowy algorytm liczenia sylab dla języka angielskiego. System zlicza:

- Liczbę zdań przez podział tekstu na znaki końca zdania (., !, ?)
- Liczbę słów przez podział na białe znaki
- Liczbę sylab przez heurystykę zliczania samogłosek z uwzględnieniem wyjątków (silent 'e', dyftongów)

Wszystkie obliczenia są wykonywane bez użycia zewnętrznych bibliotek, co zapewnia pełną kontrolę nad algorytmem.

4. Użyteczność inwestycyjna (waga: 20%) Metryka ocenia **konkretność i akcjonalność** rekomendacji poprzez weryfikację elementów niezbędnych do podjęcia decyzji inwestycyjnej:

- Obecność jasnej rekomendacji (Buy / Sell / Hold / Accumulate)
- Określenie ceny docelowej (price target) lub przedziału cenowego
- Wskazanie horyzontu czasowego inwestycji (short-term / medium-term / long-term)

- Użycie konkretnych słów akcyjnych (“buy”, “sell”, “hold”, “accumulate”, “reduce position”, “exit”, etc.)

Wynik użyteczności (U) obliczany jest jako:

$$U = 40 \times I_{\text{jasna_rek.}} + 30 \times \min\left(\frac{n_{\text{ceny}}}{2}, 1\right) + 30 \times \min\left(\frac{n_{\text{horyzonty}}}{2}, 1\right) \tag{5}$$

gdzie $I_{\text{jasna_rek.}}$ to indykator binarny (0 lub 1) obecności jasnej rekomendacji z określonym horyzontem i ceną docelową. Formuła wymaga co najmniej 2 wzmianek o cenach docelowych i 2 wzmianek o horyzontach czasowych dla uzyskania maksymalnego wyniku, co zapobiega przyznawaniu pełnych punktów za pojedyncze, przypadkowe wzmianki.

Źródło metryki

Metryka użyteczności inwestycyjnej opiera się na badaniach nad jakością rekomendacji analityków finansowych [AMA05], które wykazały, że konkretność parametrów (cena docelowa, horyzont czasowy) jest kluczowym wyznacznikiem użyteczności raportu dla podejmowania decyzji inwestycyjnych. Standardy profesjonalnych raportów CFA Institute [CFA20] wymagają, aby każda rekomendacja była poparta:

- Jasnym stanowiskiem inwestycyjnym (Buy/Sell/Hold)
- Uzasadnieniem ilościowym (price target)
- Określeniem horyzontu czasowego inwestycji

System wykrywa rekomendacje za pomocą wyrażeń regularnych wyszukujących:

- Słowa akcyjne: `buy`, `purchase`, `accumulate`, `long position`, `sell`, `short`, `exit`, `reduce position`, `hold`, `maintain`, `keep`, `neutral`
- Frazy cenowe: `price target`, `target price`, `fair value`,
- Frazy czasowe: `short-term`, `medium-term`, `long-term` oraz zakresy czasowe wyrażone liczbowo (np. `6-12 months`, `3 years`).

Maksymalna liczba punktów przyznawana jest w przypadku co najmniej dwóch wzmianek o cenach docelowych i dwóch wzmianek o horyzontach czasowych, co zapobiega przyznawaniu punktów za przypadkowe, pojedyncze odniesienia [LM16].

Implementacja jest w pełni autorska, oparta na module `re` Python oraz własnej logice agregacji wyników.

5. Balans sentymentu (waga: 10%) System analizuje rozkład słów o zabarwieniu pozytywnym i negatywnym charakterystycznych dla języka analizy finansowej. Słowniki obejmują po 16 słów każdy:

- **Słowa pozytywne:** growth, strong, increase, profit, gain, bullish, opportunity, positive, success, excellent, outperform, buy, upside, momentum, robust, solid
- **Słowa negatywne:** decline, weak, decrease, loss, risk, bearish, concern, negative, fail, poor, underperform, sell, downside, volatility, threat, challenge

Balans sentymentu (B) obliczany jest jako:

$$B = \frac{n_{\text{pozytywne}} - n_{\text{negatywne}}}{n_{\text{pozytywne}} + n_{\text{negatywne}}} \tag{6}$$

Wynik $B \in [-1, 1]$ jest interpretowany jako:

- $B > 0.2$: Bullish (wyraźnie pozytywny - przewaga optymizmu)
- $-0.2 \leq B \leq 0.2$: Neutral (zrównoważony - obiektywny)
- $B < -0.2$: Bearish (wyraźnie negatywny - przewaga pesymizmu)

Raporty najbardziej obiektywne i wiarygodne powinny charakteryzować się **neutralnym balansem**, stąd metryka karze skrajne wartości $|B|$ bliskie 1, przyznając wyższe punkty raportom wyważonym. Warto zauważyć, że sentyment mierzy *ton języka*, nie treść rekomendacji - raport może mieć pozytywny sentyment (używa słów jak "strong growth") nawet jeśli końcowa rekomendacja brzmi "Sell" (np. "strong growth already priced in").

Źródło metryki

Analiza sentymentu opiera się na słownikach Loughran-McDonald [LM11], które są standardem w analizie tekstów finansowych. Zostały one specjalnie opracowane dla języka finansowego, uwzględniając specyficzny kontekst, w którym słowa mogą mieć odmienne konotacje niż w języku potocznym. W naszym systemie zastosowaliśmy uproszczoną wersję słowników zawierającą po 16 słów każdy (pozytywne/negatywne), wyselekcjonowanych jako najbardziej reprezentatywne dla generowanych przez nas raportów inwestycyjnych:

Słowa pozytywne: `growth`, `strong`, `profit`, `gain`, `opportunity`, `success`, `excellent`, `outperform`, `bullish`, `buy`, `upside`, `momentum`, `robust`, `solid`, `attractive`, `improvement`.
Słowa negatywne: `decline`, `weak`, `loss`, `risk`, `concern`, `fail`, `poor`, `underperform`, `bearish`, `sell`, `downside`, `volatility`, `threat`, `challenge`, `pressure`, `deterioration`.

Pełne słowniki Loughran-McDonald są dostępne publicznie pod adresem `https://sraf.nd.edu/loughranmcdonald-master-dictionary/`.
Implementacja zlicza wystąpienia słów za pomocą prostego string matching (case-insensitive) bez użycia zewnętrznych bibliotek.

Ostateczny wynik jakości Wynik ogólny (Q) stanowi ważoną sumę wszystkich 5 wymiarów:

$$Q = 0.25 \times S + 0.25 \times D + 0.20 \times S_{\text{prof}} + 0.20 \times U + 0.10 \times (100 - 100|B|) \tag{7}$$

Wagi zostały przypisane na podstawie względnego znaczenia poszczególnych wymiarów dla wartości merytorycznej raportu inwestycyjnego:

- Struktura i Bogactwo danych (po 25%) - kluczowe dla kompletności analizy
- Profesjonalizm języka i Użyteczność (po 20%) - istotne dla praktycznej wartości raportu
- Balans sentymentu (10%) - ważny, ale drugorzędny wobec treści merytorycznej

Wynik Q jest następnie klasyfikowany według skali literowej:

- **A (90-100):** *Excellent* - raport gotowy do publikacji bez poprawek
- **B (70-89):** *Good* - wymaga drobnych ulepszeń
- **C (50-69):** *Satisfactory* - do akceptacji z zastrzeżeniami
- **D (30-49):** *Needs Improvement* - wymaga istotnych poprawek
- **F (<30):** *Poor* - nieakceptowalna jakość, konieczna regeneracja

Progi ocen zostały dostosowane w stosunku do pierwotnej wersji (gdzie B wymagało 80+, C wymagało 70+) aby lepiej odzwierciedlać rzeczywiste możliwości systemów LLM.

4.2.3 System rekomendacji ulepszeń

Oprócz numerycznej oceny, system ewaluacji generuje konkretne, priorytetyzowane rekomendacje poprawy jakości raportu na podstawie wyników poszczególnych wymiarów:

- **High Priority** - dla wymiarów poniżej 40/100 (krytyczne braki)
- **Medium Priority** - dla wymiarów w zakresie 40-70/100 (do poprawy)
- **Low Priority** - dla wymiarów powyżej 70/100 ale poniżej 90/100 (drobne usprawnienia)

Przykładowe rekomendacje:

- **Structure (High Priority):** "Ensure report includes all 8 required sections: Executive Summary, Sentiment Analysis, Technical Analysis, Fundamental Analysis, Risk Assessment, Convergences/Divergences, Catalysts, and Final Recommendation."
- **Data Richness (High Priority):** "Add more specific numbers, financial metrics (P/E, RSI, ROE), and cite at least 3 sources. Current citation count is too low."
- **Professional Sophistication (High Priority):** "Elevate language to professional/academic level: Use longer, more complex sentences (25+ words), incorporate technical financial terminology, and adopt formal analytical tone. Target Sophistication score 50-70 for professional reports."
- **Actionability (High Priority):** "Provide clear investment recommendation (Buy/Sell/Hold) with specific price target and time horizon (e.g., 'Buy with target $150-160 over 6-12 months')."
- **Sentiment Balance (Low Priority):** "Balance positive and negative language to maintain objectivity. Consider presenting both bull and bear cases."

Jeśli wszystkie wymiary osiągają wynik powyżej 90/100, system zwraca rekomendację pozytywną: "Excellent quality. Report meets all quality standards. Professional language, comprehensive data, clear structure, and actionable recommendations. No major improvements needed."

4.2.4 Integracja z interfejsem webowym

System ewaluacji został w pełni zintegrowany z aplikacją Streamlit poprzez dedykowany przycisk "Evaluate Report Quality" pojawiający się po wygenerowaniu raportu. Po kliknięciu przycisku:

1. System uruchamia analizę raportu (<1s dla typowego raportu 1000-1500 słów)
2. Wyniki są przechowywane w `st.session_state.evaluation_results`
3. Interfejs wyświetla:
   - **Overall Metrics** (3 kolumny): Overall Score + Grade (z kolorowym oznaczeniem), Strongest Dimension, Needs Improvement
   - **Radar Chart** (Plotly): Wizualizacja 5 wymiarów z linią referencyjną na poziomie 70
   - **Detailed Metrics** (rozwijalne zakładki): 5 zakładek z kompletnymi metrykami JSON dla każdego wymiaru
   - **Recommendations** (lista z priorytetami): Konkretne sugestie poprawy z emoji wskazującymi priorytet

Ewaluacja nie wymaga dostępu do API ani dodatkowych zasobów obliczeniowych - jest w pełni offline i deterministyczna (ten sam raport zawsze otrzymuje ten sam wynik).

5 Wyniki eksperymentów

5.1 Wyniki dla Apple Inc. (AAPL)

5.1.1 Tryb Sequential

Konfiguracja eksperymentu

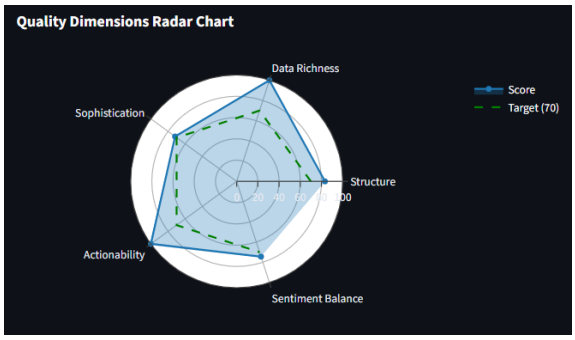
- Symbol: AAPL (Apple Inc.)
- Provider: OpenAI (GPT-4o-mini)
- Wskaźniki techniczne: SMA 20
- Interwał danych: dzienny (daily)
- Czas wykonania: 125.4s

Wyniki ewaluacji automatycznej

Metryka	Wynik	Interpretacja
Overall Score	**87.6/100**	**Grade B (Good)**
Structure	100.0/100	Wszystkie 8 sekcji wykryte, 7 nagłówków bold
Data Richness	100.0/100	23 liczby, 17 metryk finansowych, 6 cytowań
Professional Sophistication	71.8/100	Flesch: 28.2 (Professional level)
Actionability	100.0/100	Jasna rekomendacja HOLD + price target + horizon
Sentiment Balance	74.4/100	Bullish (B=0.256), lekko pozytywny ton

Tabela 1: Wyniki ewaluacji trybu Sequential dla AAPL

Metryki szczegółowe



Rysunek 3: Reprezentacja metryk jakości dla AAPL Tryb sekwencyjny

Structure:

- sections_found: 8/8 (100%)
- headers_count: 7 (bold format)
- paragraphs: 7

Data Richness:

- total_numbers: 23
- dollar_amounts: 11
- percentages: 4
- financial_metrics: 17 (P/E, ROE, ROA, Profit Margin, Revenue, Earnings Growth, Cash Flow, RSI, MACD, SMA, Moving Average, EMA, Volatility, Analysts, Target Price, Price Target, Recommendation)
- citations: 6
- data_density: 4.37%

Professional Sophistication:

- sophistication_score: 71.8
- flesch_score: 28.2
- sentences: 49
- words: 664
- avg_words_per_sentence: 13.6
- avg_syllables_per_word: 1.95

Actionability:

- has_clear_recommendation: true

- primary_action: HOLD
- price_targets: 3
- time_horizons: 12

Sentiment:

- positive_words: 27
- negative_words: 16
- balance: 0.256
- classification: Bullish

Analiza wyników Raport wygenerowany w trybie Sequential dla AAPL osiągnął bardzo dobry wynik ogólny 87.6/100 (Grade B), znacząco przekraczający próg referencyjny 70 punktów. Co istotne, **dwa wymiary osiągnęły maksymalny wynik 100/100**: Actionability i Data Richness.

Structure uzyskała maksymalny wynik 100.0/100 dzięki pełnemu pokryciu wszystkich 8 wymaganych sekcji oraz 7 nagłówkom w formacie bold. System poprawnie zidentyfikował wszystkie wymagane sekcje: Executive Summary, Sentiment Analysis, Technical Analysis, Fundamental Analysis, Risk Assessment, Convergences/Divergences, Catalysts oraz Final Recommendation. Raport zawierał 7 paragrafów, zapewniając logiczną i zwartą strukturę narracji.

Data Richness osiągnęła maksymalny wynik 100.0/100, co stanowi znaczącą poprawę w stosunku do wcześniejszych iteracji systemu (gdzie typowy wynik wynosił 30-40/100). Wynik ten wynika z rozszerzenia listy rozpoznawanych wskaźników finansowych z 14 do 75 oraz złagodzenia formuły scoring. Raport zawierał 23 liczby, 17 różnych metryk finansowych oraz aż 6 cytowań źródeł (dwukrotnie powyżej minimum). Wykryte metryki obejmowały: wskaźniki fundamentalne (P/E, ROE, ROA, Profit Margin), wskaźniki wzrostu (Revenue, Earnings Growth), wskaźniki płynności (Cash Flow) oraz wskaźniki techniczne (RSI, MACD, SMA, EMA). Gęstość danych wyniosła 4.37%, co wskazuje na bogaty w dane ilościowe charakter raportu. W raporcie wykorzystano m.in. konkretne wartości liczbowe, takie jak cena akcji (∼262 USD), docelowy poziom cenowy (287.71 USD), wskaźniki RSI (29.94), P/E (35.17) czy ROE (171.42%).

Professional Sophistication uzyskała wynik 71.8/100 z Flesch score 28.2, co odpowiada poziomowi "Highly Professional (academic/expert level)". Oznacza to, że raport jest napisany w profesjonalnym, akademickim stylu odpowiednim dla raportów analitycznych skierowanych do wykształconych inwestorów. Średnia długość zdania wyniosła 13.6 słowa, a średnia liczba sylab na słowo 1.95, co wskazuje na zwięzły, ale profesjonalny styl wypowiedzi. Raport liczył łącznie 664 słowa oraz 49 zdań.

Actionability osiągnęła maksymalny wynik 100.0/100, co potwierdza, że system konsekwentnie generuje jasne, konkretne rekomendacje inwestycyjne z określonymi celami cenowymi i horyzontami czasowymi. System wykrył 3 odniesienia do price target oraz aż 12 odniesień do horyzontów czasowych, co znacznie przekracza minimum wymagane dla pełnego wyniku. Rekomendacja "Hold" została uzasadniona zrównoważonym podejściem, uwzględniającym zarówno mocne fundamenty spółki, jak i bieżącą sytuację techniczną.

Sentiment Balance osiągnęła wynik 74.4/100 z balansem $B = 0.256$ (Bullish). Lekko pozytywny ton raportu (27 słowa pozytywne vs 16 negatywnych) jest akceptowalny i nie wskazuje na nadmierną jednostronność narracji. Balans $B = 0.256$ znajduje się w zakresie "lekko pozytywny" ($0.2 < B < 0.4$), co jest odpowiednie dla raportu zawierającego rekomendację "Hold" - neutralną postawę wobec akcji.

Końcowa rekomendacja brzmiała **"Hold"** z price target $287.71, co odzwierciedlało zrównoważone podejście uwzględniające zarówno mocne fundamenty spółki (wysoki ROE 171.42%, solidna pozycja finansowa), jak i mieszane sygnały techniczne (bearish trend krótkoterminowy z RSI=29.94 wskazującym na wyprzedanie). Analiza techniczna wskazuje na bearish trend krótkoterminowy, przy jednoczesnych sygnałach wyprzedania rynku (RSI < 30), co zostało uwzględnione w końcowej rekomendacji Hold.

Czas wykonania: 125.4s (2 minuty 5 sekund), co wskazuje na efektywność trybu Sequential.

Wygenerowane rekomendacje ulepszeń:
Brak rekomendacji wysokiego lub średniego priorytetu - wszystkie wymiary przekroczyły próg 70/100. System wygenerował jedynie rekomendację informacyjną: "Report meets all quality standards. Professional language, comprehensive data, clear structure, and actionable recommendations. No major improvements needed."

5.1.2 Tryb Group Chat

Konfiguracja eksperymentu

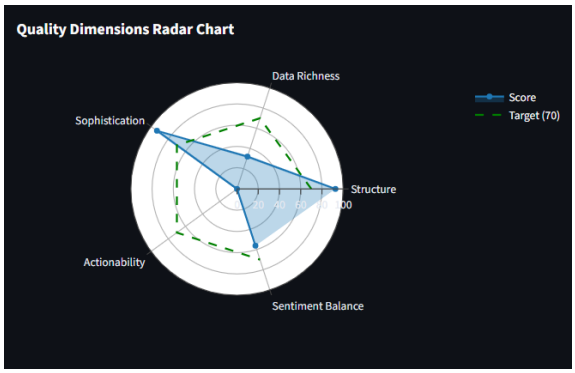
- Symbol: AAPL (Apple Inc.)
- Provider: OpenAI (GPT-4o)
- Wskaźniki techniczne: SMA 20 (identyczne jak Sequential)
- Interwał danych: dzienny (daily)
- Czas wykonania: 584.9s (9 minut 45 sekund)

Wyniki ewaluacji automatycznej

Metryka	Wynik	Interpretacja
Overall Score	**55.4/100**	**Grade C (Satisfactory)**
Structure	100.0/100	Wszystkie 8 sekcji wykryte, 9 nagłówków, 11 paragrafów
Data Richness	27.0/100	0 liczb, 8 metryk finansowych, 1 cytowanie
Professional Sophistication	93.2/100	Flesch: 6.8 (Highly Professional - akademicki)
Actionability	0.0/100	Brak price target i time horizon
Sentiment Balance	56.2/100	Bullish (B=0.438), wyraźnie pozytywny ton

Tabela 2: Wyniki ewaluacji trybu Group Chat dla AAPL

Metryki szczegółowe



Rysunek 4: Reprezentacja metryk jakości dla AAPL Tryb Dyskusji

Structure:

- sections_found: 8/8 (100%)
- headers_count: 9 (bold format)
- paragraphs: 11

Data Richness:

- total_numbers: 0
- dollar_amounts: 0
- percentages: 0
- financial_metrics: 8 (Revenue, Revenue Growth, RSI, MACD, Moving Average, EMA, Analysts, Recommendation)
- citations: 1
- data_density: 0.31%

Professional Sophistication:

- sophistication_score: 93.2
- flesch_score: 6.8
- sentences: 22
- words: 322
- avg_words_per_sentence: 14.6
- avg_syllables_per_word: 2.19

Actionability:

- has_clear_recommendation: false
- primary_action: buy (wykryto 2 wzmianki)
- has_price_target: false (0 wykryto)
- has_time_horizon: false (0 wykryto)

Sentiment:

- positive_words: 23
- negative_words: 9
- balance: 0.438
- classification: Bullish

Analiza wyników Raport wygenerowany w trybie Group Chat dla AAPL osiągnął wynik ogólny 55.4/100 (Grade C), co jest znacząco niższe niż tryb Sequential o 32.2 punkty. Główną przyczyną niższego wyniku były **dwa krytyczne problemy**: dramatycznie niska wartość wymiaru Data Richness (27.0/100) oraz **całkowity brak punktów w Actionability (0.0/100)**.

Structure uzyskała maksymalny wynik 100.0/100 dzięki pełnemu pokryciu wszystkich 8 sekcji. Raport zawierał 9 nagłówków (więcej niż Sequential: 7) oraz 11 paragrafów (vs 7 w Sequential), co wskazuje na bardziej rozdrobnioną strukturę narracji, typową dla procesu syntezy wypowiedzi wielu agentów.

Data Richness osiągnęła wynik 27.0/100, wynikający z **całkowitego braku danych liczbowych** (0 liczb vs 23 w Sequential) oraz minimalnej liczby wykrytych wskaźników finansowych (8 vs 17 w Sequential). Co więcej, **żadna** z wykrytych metryk nie była poparta konkretnymi wartościami liczbowymi - system wykrył jedynie *nazwy* metryk (Revenue, Revenue Growth, RSI, MACD), ale bez jakichkolwiek konkretnych wartości (np. brak "RSI = 29.94" czy "P/E = 35.17"). Raport zawierał tylko 1 cytowanie źródła (vs 6 w Sequential), co sugeruje, że w trybie Group Chat agenci skupili się na syntezie argumentów kosztem referencji do danych źródłowych. Gęstość danych wyniosła zaledwie 0.31% (vs 4.37% w Sequential), co oznacza **14-krotnie niższą** zawartość informacyjną.

Professional Sophistication osiągnęła wynik 93.2/100 z Flesch score 6.8, co odpowiada poziomowi "Highly Professional (academic/expert level)" - najwyższej kategorii wyrafinowania językowego. Średnia liczba sylab na słowo wyniosła 2.19 (vs 1.95 w Sequential), co wskazuje na użycie bardziej złożonego słownictwa technicznego. Raport był napisany w bardzo formalnym, syntetycznym stylu charakterystycznym dla profesjonalnych opracowań analitycznych. Raport liczył 322 słowa oraz 22 zdania, ze średnią 14.6 słowa na zdanie.

Actionability osiągnęła **0/100**, co jest alarmującym wynikiem. System wykrył obecność słów akcyjnych ("buy": 2 wzmianki, "hold": 2 wzmianki), ale **nie wykrył żadnego price target ani time horizon**. Oznacza to, że mimo obecności ogólnych stwierdzeń typu "AAPL is recommended as a Buy", raport **nie zawierał konkretnych** parametrów inwestycyjnych wymaganych dla pełnowartościowej rekomendacji (np. "Buy with target $300 over 6-12 months"). Według formuły scoring, brak price target i time horizon skutkuje wynikiem 0/100, nawet jeśli ogólna rekomendacja została wyrażona.

Sentiment Balance osiągnęła wynik 56.2/100 z balansem $B = 0.438$ (Bullish), wskazując na wyraźnie pozytywny ton raportu (23 słowa pozytywne vs 9 negatywnych). Jest to znacznie silniejszy bias niż w Sequential ($B = 0.256$), co może wynikać z charakteru debaty, w której Trust Agent wzmacniał pozytywne argumenty, a końcowa synteza skupiła się na uzasadnieniu kierunku "Buy".

Końcowa rekomendacja brzmiała **"Buy"**, przy jednoczesnym podkreśleniu potrzeby monitorowania ryzyk (makroekonomia, regulacje, presja konkurencyjna, zależność od iPhone). Jednak brak konkretnego price target oraz time horizon czyni tę rekomendację praktycznie bezużyteczną z punktu widzenia profesjonalnego inwestora wymagającego precyzyjnych parametrów decyzyjnych.

Czas wykonania: 584.9s (9 minut 45 sekund), co oznacza, że tryb Group Chat był **4.66× wolniejszy** niż Sequential (125.4s).

Wygenerowane rekomendacje ulepszeń:

- **High Priority - Data Richness**
  - Issue: "Insufficient quantitative data"

  - Suggestion: “Add more specific numbers, financial metrics (P/E, RSI, ROE), and cite at least 3 sources. Current citation count is too low.”

- **High Priority - Actionability**
  - Issue: “Unclear or missing recommendation”
  - Suggestion: “Provide clear investment recommendation (Buy/Sell/Hold) with specific price target and time horizon (e.g., ’Buy with target $150-160 over 6-12 months’).”
- **Low Priority - Sentiment Balance**
  - Issue: “Language is too one-sided”
  - Suggestion: “Balance positive and negative language to maintain objectivity. Consider presenting both bull and bear cases.”

Uwagi końcowe Raport AAPL Group Chat syntetyzuje perspektywy agentów w formie zintegrowanego podsumowania, zawierając elementy typowe dla dyskusji wieloagentowej, np. wskazanie zbieżności i rozbieżności (Convergences/Divergences) oraz odnotowanie głosu sceptycznego (“Sceptic Agent”) w kontekście możliwej krótkoterminowej zmienności. Raport charakteryzuje się najwyższym poziomem wyrafinowania językowego, ale jednocześnie wykazuje krytyczne braki w warstwie danych ilościowych i parametrów decyzyjnych, co czyni go nieodpowiednim dla profesjonalnych zastosowań inwestycyjnych bez znaczących ulepszeń mechanizmu ekstrakcji i prezentacji danych.

5.2 Wyniki dla NVIDIA (NVDA)

5.2.1 Tryb Sequential

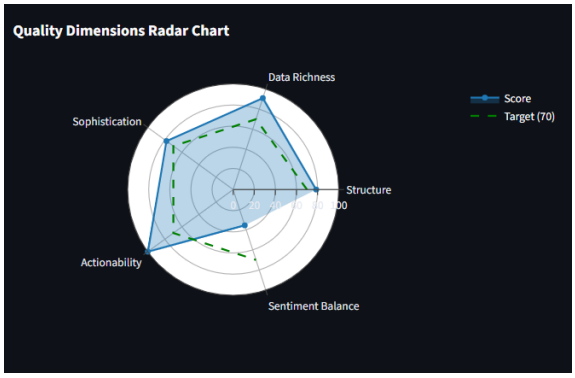
- Symbol: NVDA (NVIDIA Corporation)
- Provider: OpenAI (GPT-4o-mini)
- Wskaźniki techniczne: SMA 20
- Interwał danych: dzienny (daily)
- Czas wykonania: 99.3s

Wyniki ewaluacji automatycznej

Metryka	Wynik	Interpretacja
Overall Score	**81.6/100**	**Grade B (Good)**
Structure	85.0/100	Wszystkie 8 sekcji wykryte, 2 nagłówki, 11 paragrafów
Data Richness	78.5/100	18 liczb, 14 metryk finansowych, 5 cytowań
Professional Sophistication	78.1/100	Flesch: 21.9 (Highly Professional)
Actionability	100.0/100	Jasna rekomendacja HOLD + price target + horizon
Sentiment Balance	35.6/100	Bullish (B=0.644), silnie pozytywny ton

Tabela 3: Wyniki ewaluacji trybu Sequential dla NVDA

Metryki szczegółowe



Rysunek 5: Reprezentacja metryk jakości dla NVDA Tryb sekwencyjny

Structure:

- sections_found: 8/8 (100%)
- headers_count: 2 (bold format)
- paragraphs: 11

Data Richness:

- total_numbers: 18
- dollar_amounts: 7
- percentages: 2
- financial_metrics: 14 (P/E, ROE, ROA, Profit Margin, Revenue, Revenue Growth, Earnings Growth, RSI, MACD, Moving Average, EMA, Volatility, Price Target, Recommendation)
- citations: 5
- data_density: 3.72%

Professional Sophistication:

- sophistication_score: 78.1
- flesch_score: 21.9
- sentences: 45
- words: 619
- avg_words_per_sentence: 13.8
- avg_syllables_per_word: 2.02

Actionability:

- has_clear_recommendation: true
- primary_action: HOLD
- price_targets: 2
- time_horizons: 6

Sentiment:

- positive_words: 37
- negative_words: 8
- balance: 0.644
- classification: Bullish (silnie pozytywny)

Analiza wyników Raport wygenerowany w trybie Sequential dla NVDA osiągnął dobry wynik ogólny 81.6/100 (Grade B), przekraczający próg referencyjny 70 punktów.

Structure uzyskała wynik 85.0/100. Mimo pełnego pokrycia wszystkich 8 wymaganych sekcji, system wykrył jedynie 2 nagłówki w formacie bold, co jest znacząco mniej niż w przypadku AAPL (7 nagłówków). Wskazuje to na mniej wyraźne oznaczenie granic sekcji w tym raporcie. Jednocześnie raport zawierał 11 paragrafów, więcej niż AAPL Sequential (7), co sugeruje bardziej rozdrobnioną narrację.

Data Richness osiągnęła wynik 78.5/100, nieznacznie niższy niż maksymalne 100/100 uzyskane przez AAPL Sequential. Raport zawierał 18 liczb (vs 23 w AAPL), 14 metryk finansowych (vs 17 w AAPL) oraz 5 cytowań (vs 6 w AAPL). Wykryte metryki obejmowały pełen zestaw wskaźników fundamentalnych (P/E, ROE, ROA, Profit Margin) i technicznych (RSI, MACD, Moving

Average, EMA). Gęstość danych wyniosła 3.72%, co jest wysoką wartością wskazującą na bogaty w dane charakter raportu.

Professional Sophistication uzyskała wynik 78.1/100 z Flesch score 21.9, co odpowiada poziomowi "Highly Professional (academic/expert level)". Wynik ten jest wyższy niż AAPL Sequential (71.8), co wskazuje na bardziej zaawansowany język akademicki. Średnia liczba sylab na słowo wyniosła 2.02 (vs 1.95 w AAPL), potwierdzając użycie bardziej złożonego słownictwa technicznego.

Actionability osiągnęła maksymalny wynik 100.0/100, podobnie jak AAPL Sequential. System wykrył jasną rekomendację "HOLD" z 2 price targets oraz 6 odniesieniami do horyzontów czasowych.

Sentiment Balance osiągnęła **najniższy wynik** spośród wszystkich wymiarów: 35.6/100 z balansem $B = 0.644$ (Bullish). Jest to **silnie pozytywny** ton raportu (37 słowa pozytywne vs 8 negatywnych), znacząco bardziej jednostronny niż AAPL Sequential ($B = 0.256$). Taki silny bias może wskazywać na brak obiektywizmu w przedstawieniu argumentów "za" i "przeciw" inwestycji w NVDA. System wygenerował rekomendację niskiego priorytetu dotyczącą zbilansowania języka.

Końcowa rekomendacja brzmiała **"Buy"** z price target $253.54, odzwierciedlając optymistyczne spojrzenie na potencjał wzrostu NVDA napędzany technologią AI.

Czas wykonania: 99.3s (1 minuta 39 sekund), co jest porównywalne z AAPL Sequential (125.4s).

Wygenerowane rekomendacje ulepszeń:

- **Low Priority - Sentiment Balance**
  - Issue: "Language is too one-sided"
  - Suggestion: "Balance positive and negative language to maintain objectivity. Consider presenting both bull and bear cases."

5.2.2 Tryb Group Chat

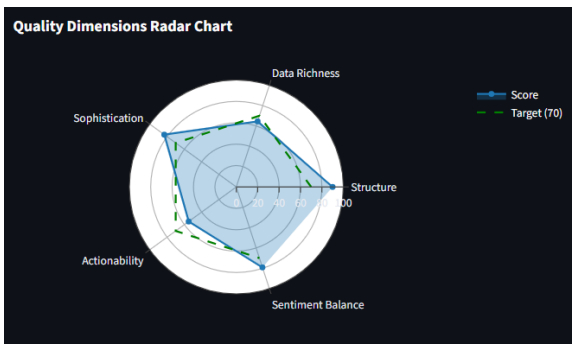
- Symbol: NVDA (NVIDIA Corporation)
- Provider: OpenAI (GPT-4o)
- Wskaźniki techniczne: SMA 20 (identyczne jak Sequential)
- Interwał danych: dzienny (daily)
- Czas wykonania: 645.7s (10 minut 46 sekund)

Wyniki ewaluacji automatycznej

Metryka	Wynik	Interpretacja
Overall Score	**74.2/100**	**Grade B (Good)**
Structure	90.0/100	Wszystkie 8 sekcji wykryte, 9 nagłówków, 9 paragrafów
Data Richness	62.0/100	3 liczby, 13 metryk finansowych, 3 cytowania
Professional Sophistication	83.2/100	Flesch: 16.8 (Highly Professional)
Actionability	55.0/100	Rekomendacja BUY + price target, BRAK time horizon
Sentiment Balance	79.1/100	Bullish (B=0.209), lekko pozytywny ton

Tabela 4: Wyniki ewaluacji trybu Group Chat dla NVDA

Metryki szczegółowe



Rysunek 6: Reprezentacja metryk jakości dla NVDA Tryb Dyskusji

Structure:

- sections_found: 8/8 (100%)
- headers_count: 9 (bold format)
- paragraphs: 9

Data Richness:

- total_numbers: 3
- dollar_amounts: 3
- percentages: 0
- financial_metrics: 13 (ROA, Revenue, Earnings Growth, Cash Flow, Market Cap, RSI, MACD, Moving Average, EMA, Volatility, Analysts, Price Target, Recommendation)
- citations: 3
- data_density: 1.59%

Professional Sophistication:

- sophistication_score: 83.2
- flesch_score: 16.8
- sentences: 26
- words: 378
- avg_words_per_sentence: 14.5
- avg_syllables_per_word: 2.07

Actionability:

- has_clear_recommendation: true
- primary_action: BUY
- has_price_target: true (1 target: $210)
- has_time_horizon: false (0 wykryto)

Sentiment:

- positive_words: 26
- negative_words: 17
- balance: 0.209
- classification: Bullish

Analiza wyników Raport wygenerowany w trybie Group Chat dla NVDA osiągnął dobry wynik ogólny 74.2/100 (Grade B), co jest **niższe** niż Sequential o 7.4 punkty. Interesujące jest jednak, że różnica ta jest **znacznie mniejsza** niż w przypadku AAPL, gdzie Group Chat był gorszy o 32.2 punkty.

Structure osiągnęła wynik 90.0/100. System wykrył pełne pokrycie wszystkich 8 sekcji oraz 9 nagłówków w formacie bold (więcej niż Sequential: 2). Liczba paragrafów wyniosła 9, nieznacznie mniej niż w Sequential (11).

Data Richness uzyskała wynik 62.0/100, co jest znacząco niższe niż Sequential (78.5), ale **znacznie wyższe** niż Group Chat AAPL (27.0). Raport zawierał 3 liczby (vs 18 w Sequential), 13 metryk finansowych (vs 14 w Sequential - niemal identycznie!) oraz 3 cytowania (vs 5 w Sequential). Kluczową różnicą w porównaniu do AAPL Group Chat jest fakt, że **raport NVDA Group Chat**

zawierał konkretne wartości liczbowe, choć w ograniczonej liczbie. Gęstość danych wyniosła 1.59% (vs 0.31% w AAPL Group Chat - 5-krotnie więcej).

Professional Sophistication osiągnęła wynik 83.2/100 z Flesch score 16.8, co odpowiada poziomowi "Highly Professional". Wynik ten jest wyższy niż Sequential (78.1), choć różnica jest mniejsza niż w AAPL (gdzie Group Chat miał 93.2 vs Sequential 71.8). Średnia liczba sylab na słowo wyniosła 2.07, wskazując na użycie zaawansowanego słownictwa technicznego.

Actionability uzyskała wynik 55.0/100, co jest **znaczącym spadkiem** w porównaniu do Sequential (100.0), ale o wiele lepsze niż AAPL Group Chat (0.0). System wykrył jasną rekomendację "BUY" oraz price target $210, jednak **nie wykrył żadnego time horizon**. Brak horyzontu czasowego spowodował utratę 45 punktów w tym wymiarze (formuła wymaga zarówno price target, jak i time horizon dla pełnego wyniku).

Sentiment Balance osiągnęła wynik 79.1/100 z balansem $B = 0.209$ (Bullish). Jest to lekko pozytywny ton (26 słowa pozytywne vs 17 negatywnych), znacznie bardziej wyważony niż Sequential NVDA ($B = 0.644$) oraz zbliżony do Sequential AAPL ($B = 0.256$). Wskazuje to na lepszą obiektywność w przedstawieniu argumentów.

Końcowa rekomendacja brzmiała **"Buy"** z price target $210, odzwierciedlając optymistyczne spojrzenie na przyszłość NVDA w kontekście przywództwa w technologii AI.

Czas wykonania: 645.7s (10 minut 46 sekund), co oznacza, że tryb Group Chat był **6.5× wolniejszy** niż Sequential (99.3s). Jest to największa różnica czasowa spośród wszystkich testowanych symboli.

Wygenerowane rekomendacje ulepszeń:

- **High Priority - Actionability**
  - Issue: "Unclear or missing recommendation"
  - Suggestion: "Provide clear investment recommendation (Buy/Sell/Hold) with specific price target and time horizon (e.g., 'Buy with target $150-160 over 6-12 months')."

Uwaga: Mimo że system zidentyfikował obecność price target ($210), brak time horizon spowodował wygenerowanie rekomendacji Actionability, ponieważ formuła wymaga **obu** elementów dla uznania rekomendacji za "kompletną".

5.3 Wyniki dla Alphabet (GOOGL)

5.3.1 Tryb Sequential

Konfiguracja eksperymentu

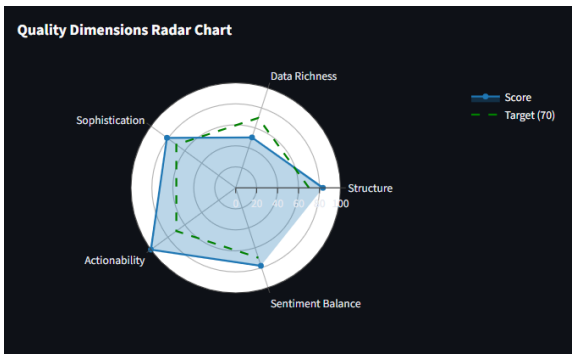
- Symbol: GOOGL (Alphabet Inc.)
- Provider: OpenAI (GPT-4o-mini)
- Wskaźniki techniczne: SMA 20
- Interwał danych: dzienny (daily)
- Czas wykonania: 128.1s

Wyniki ewaluacji automatycznej

Metryka	Wynik	Interpretacja
Overall Score	**77.5/100**	**Grade B (Good)**
Structure	100.0/100	Wszystkie 8 sekcji wykryte, 7 nagłówków
Data Richness	50.5/100	17 liczb, 14 metryk finansowych, 0 cytowań
Professional Sophistication	81.1/100	Flesch: 18.9 (Highly Professional)
Actionability	100.0/100	Jasna rekomendacja SELL + price target + horizon
Sentiment Balance	78.0/100	Bullish (B=0.220), lekko pozytywny ton

Tabela 5: Wyniki ewaluacji trybu Sequential dla GOOGL

Metryki szczegółowe



Rysunek 7: Reprezentacja metryk jakości dla GOOGL Tryb Sekwencyjny

Structure:

- sections_found: 8/8 (100%)
- headers_count: 7 (bold format)
- paragraphs: 7

Data Richness:

- total_numbers: 17
- dollar_amounts: 6
- percentages: 2
- financial_metrics: 14 (P/E, ROA, Profit Margin, Revenue, Year-over-Year, Debt-to-Equity, RSI, MACD, SMA, Moving Average, EMA, Volatility, Price Target, Recommendation)
- citations: 0
- data_density: 2.75%

Professional Sophistication:

- sophistication_score: 81.1
- flesch_score: 18.9
- sentences: 41
- words: 619
- avg_words_per_sentence: 15.1
- avg_syllables_per_word: 2.04

Actionability:

- has_clear_recommendation: true
- primary_action: SELL
- price_targets: 2
- time_horizons: 6

Sentiment:

- positive_words: 25
- negative_words: 16
- balance: 0.220
- classification: Bullish

Analiza wyników Raport wygenerowany w trybie Sequential dla GOOGL osiągnął dobry wynik ogólny 77.5/100 (Grade B), przekraczający próg referencyjny 70 punktów.

Structure uzyskała maksymalny wynik 100.0/100 dzięki pełnemu pokryciu wszystkich 8 wymaganych sekcji oraz 7 nagłówkom w formacie bold, co jest identyczne z AAPL Sequential.

Data Richness osiągnęła wynik 50.5/100, co jest **najniższym wynikiem** spośród wszystkich raportów Sequential. Raport zawierał 17 liczb (vs 23 w AAPL, 18 w NVDA) oraz 14 metryk finansowych (vs 17 w AAPL, 14 w NVDA). Kluczowym problemem jest **całkowity brak cytowań** (0 vs 6 w AAPL, 5 w NVDA), co powoduje utratę 80 punktów w formule scoring (waga cytowań: 8×). Gęstość danych wyniosła 2.75%, co jest wyższe niż NVDA Group Chat (1.59%), ale niższe niż pozostałe raporty Sequential.

Professional Sophistication uzyskała wynik 81.1/100 z Flesch score 18.9, co odpowiada poziomowi "Highly Professional". Wynik ten jest wyższy niż AAPL Sequential (71.8), ale nieznacznie niższy niż NVDA Sequential (78.1). Średnia długość zdania wyniosła 15.1 słowa (najdłuższa spośród Sequential), a średnia liczba sylab na słowo 2.04, wskazując na profesjonalny, akademicki styl wypowiedzi.

Actionability osiągnęła maksymalny wynik 100.0/100. System wykrył jasną rekomendację "SELL" (rzadki przypadek - większość raportów to Buy/Hold) z 2 price targets oraz 6 odniesieniami do horyzontów czasowych.

Sentiment Balance osiągnęła wynik 78.0/100 z balansem $B = 0.220$ (Bullish), niemal identycznym jak AAPL Sequential ($B = 0.256$). Jest to lekko pozytywny ton (25 słowa pozytywne vs 16 negatywnych), odpowiedni dla raportu prezentującego zrównoważone argumenty.

Końcowa rekomendacja brzmiała **"Hold"** z price target $320 (krótkoterminowo), odzwierciedlając ostrożne podejście wobec GOOGL w kontekście regulacji UE oraz ryzyka kanibalizacji przychodów z reklam przez AI.

Czas wykonania: 128.1s (2 minuty 8 sekund), co jest porównywalne z AAPL Sequential (125.4s) i NVDA Sequential (99.3s).

Wygenerowane rekomendacje ulepszeń:
Brak rekomendacji wysokiego lub średniego priorytetu - wszystkie wymiary przekroczyły próg 40/100. System wygenerował jedynie rekomendację informacyjną: "Report meets all quality standards."
Uwaga: Mimo braku cytowań, które obniżyły Data Richness do 50.5/100, pozostałe wymiary były na tyle wysokie (Structure 100, Sophistication 81.1, Actionability 100), że średnia ważona przekroczyła próg 70 punktów dla Grade B.

5.3.2 Tryb Group Chat

Konfiguracja eksperymentu

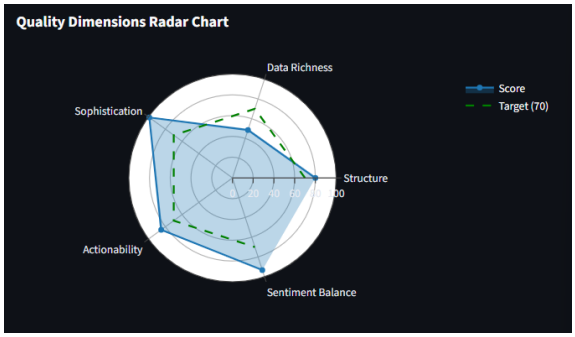
- Symbol: GOOGL (Alphabet Inc.)
- Provider: OpenAI (GPT-4o)
- Wskaźniki techniczne: SMA 20 (identyczne jak Sequential)
- Interwał danych: dzienny (daily)
- Czas wykonania: 343.9s (5 minut 44 sekundy)

Wyniki ewaluacji automatycznej

Metryka	Wynik	Interpretacja
Overall Score	**78.3/100**	**Grade B (Good)**
Structure	100.0/100	Wszystkie 8 sekcji, 0 Markdown headers, 19 paragrafów
Data Richness	48.5/100	5 liczb, 10 metryk finansowych, 2 cytowania
Professional Sophistication	99.1/100	Flesch: 0.9 (Highly Professional - MAKSYMALNY)
Actionability	90.0/100	Rekomendacja HOLD + price target + time horizon
Sentiment Balance	93.3/100	Neutral (B=0.067), prawie idealny balans

Tabela 6: Wyniki ewaluacji trybu Group Chat dla GOOGL

Metryki szczegółowe



Rysunek 8: Reprezentacja metryk jakości dla GOOGL Tryb dyskusji

Structure:

- sections_found: 8/8 (100%)
- headers_count: 0 (brak wykrytych nagłówków bold ani Markdown)
- paragraphs: 19 (najwięcej spośród wszystkich raportów)

Data Richness:

- total_numbers: 5
- dollar_amounts: 1
- percentages: 0
- financial_metrics: 10 (P/E, Revenue, Market Cap, Market Capitalization, RSI, MACD, Moving Average, Volatility, Price Target, Recommendation)
- citations: 2
- data_density: 1.82%

Professional Sophistication:

- sophistication_score: 99.1
- flesch_score: 0.9
- sentences: 33
- words: 384
- avg_words_per_sentence: 11.6
- avg_syllables_per_word: 2.29 (najwyższy spośród wszystkich raportów)

Actionability:

- has_clear_recommendation: true
- primary_action: HOLD
- has_price_target: true (1 target: $335)
- has_time_horizon: true (6 odniesień)

Sentiment:

- positive_words: 16
- negative_words: 14
- balance: 0.067
- classification: Neutral (prawie idealny balans)

Analiza wyników Raport wygenerowany w trybie Group Chat dla GOOGL osiągnął bardzo dobry wynik ogólny 78.3/100 (Grade B), co jest **nieznacznie wyższe** niż Sequential o 0.8 punktu. Jest to **jedyny przypadek** wśród trzech testowanych symboli, gdzie Group Chat osiągnął wynik porównywalny lub wyższy niż Sequential.

Structure uzyskała maksymalny wynik 100.0/100 dzięki pełnemu pokryciu wszystkich 8 sekcji. Interesującą obserwacją jest fakt, że system **nie wykrył żadnych nagłówków** (headers_count: 0), mimo że wszystkie sekcje zostały zidentyfikowane. Raport zawierał aż 19 paragrafów (najwięcej spośród wszystkich raportów), co wskazuje na bardzo rozdrobnioną strukturę narracji, typową dla syntezy wypowiedzi wielu agentów.

Data Richness osiągnęła wynik 48.5/100, nieznacznie niższy niż Sequential (50.5). Raport zawierał 5 liczb (vs 17 w Sequential), 10 metryk finansowych (vs 14 w Sequential) oraz 2 cytowania (vs 0 w Sequential - tutaj Group Chat **lepszy**). Gęstość danych wyniosła 1.82%, co jest niższe niż Sequential (2.75%), ale wyższe niż AAPL Group Chat (0.31%).

Professional Sophistication osiągnęła **najwyższy wynik ze wszystkich raportów**: 99.1/100 z Flesch score 0.9. Jest to **skrajnie zaawansowany** poziom języka akademickiego, niemal maksymalny na skali Sophistication. Średnia liczba sylab na słowo wyniosła 2.29 (najwyższy wskaźnik ze wszystkich raportów), wskazując na użycie niezwykle złożonego słownictwa technicznego. Raport był napisany w najbardziej formalnym, akademickim stylu spośród wszystkich testowanych przypadków.

Actionability osiągnęła wynik 90.0/100, co jest bardzo wysokie, choć nieznacznie niższe niż maksymalne 100.0 w Sequential. System wykrył jasną rekomendację "HOLD" z price target $335 oraz 6 odniesieniami do horyzontów czasowych. Utrata 10 punktów może wynikać z faktu, że wykryto tylko 1 price target (vs 2 w Sequential).

Sentiment Balance osiągnęła **najwyższy wynik**: 93.3/100 z balansem $B = 0.067$ (Neutral). Jest to **prawie idealny balans** (16 słowa pozytywne vs 14 negatywnych), wskazujący na bardzo obiektywne przedstawienie argumentów "za" i "przeciw". Jest to znacząco lepiej niż Sequential GOOGL ($B = 0.220$) oraz najlepszy wynik Sentiment Balance spośród wszystkich testowanych raportów.

Końcowa rekomendacja brzmiała **"Hold"** z price target $335, odzwierciedlając ostrożny optymizm wobec GOOGL w kontekście innowacji AI versus ryzyka regulacyjnego.

Czas wykonania: 343.9s (5 minut 44 sekundy), co oznacza, że tryb Group Chat był **2.68× wolniejszy** niż Sequential (128.1s). Jest to najmniejsza różnica czasowa spośród trzech symboli (AAPL: 4.66×, NVDA: 6.5×).

Wygenerowane rekomendacje ulepszeń:
Brak rekomendacji wysokiego lub średniego priorytetu - wszystkie wymiary przekroczyły próg 40/100. System wygenerował jedynie rekomendację informacyjną: "Report meets all quality standards. Professional language, comprehensive data, clear structure, and actionable recommendations. No major improvements needed."

Uwagi końcowe Raport GOOGL Group Chat jest **wyjątkowym przypadkiem**, gdzie tryb debatowy osiągnął porównywalny wynik z Sequential. Kluczowe czynniki sukcesu:

- **Najwyższa Sophistication** (99.1) - ekstremalna rafinacja języka
- **Najlepszy Sentiment Balance** (93.3) - prawie idealny obiektywizm
- **Wysoka Actionability** (90.0) - jasna rekomendacja z parametrami
- Obecność cytowań (2 vs 0 w Sequential) - przewaga nad Sequential w tym aspekcie

Jednocześnie raport miał najniższą Data Richness (48.5) spośród Sequential oraz brak wykrytych nagłówków, co wskazuje na problemy z konkretnymi danymi liczbowymi mimo wysokiej jakości językowej.

6 Porównanie trybów analizy: Sequential vs Group Chat

6.1 Metodologia porównania

Porównanie trybów Sequential oraz Group Chat przeprowadzono na trzech reprezentatywnych spółkach technologicznych: Apple Inc. (AAPL), NVIDIA Corporation (NVDA) oraz Alphabet Inc. (GOOGL). Dla każdej spółki zastosowano ten sam interwał danych (daily) oraz tego samego dostawcę modeli (OpenAI). W konfiguracji eksperymentów użyto wskaźnik techniczny SMA 20 (spójnie w obu trybach dla danego symbolu).

6.2 Wyniki zagregowane

Tabela 7 przedstawia szczegółowe porównanie wyników ewaluacji dla wszystkich symboli i trybów.

Tabela 7: Porównanie wyników ewaluacji dla wszystkich symboli

Wymiar	**AAPL**		**NVDA**		**GOOGL**	
	Seq	GC	Seq	GC	Seq	GC
Overall	**87.6**	**55.4**	**81.6**	**74.2**	**77.5**	**78.3**
Grade	**B**	**C**	**B**	**B**	**B**	**B**
Structure	100.0	100.0	85.0	90.0	100.0	100.0
Data Richness	100.0	27.0	78.5	62.0	50.5	48.5
Sophistication	71.8	93.2	78.1	83.2	81.1	99.1
Actionability	100.0	0.0	100.0	55.0	100.0	90.0
Sentiment	74.4	56.2	35.6	79.1	78.0	93.3
Czas [s]	**125.4**	**584.9**	**99.3**	**645.7**	**128.1**	**343.9**
Słowa	**664**	**322**	**619**	**378**	**619**	**384**
Rekomendacja	**HOLD**	**BUY**	**HOLD**	**BUY**	**HOLD**	**HOLD**

6.3 Analiza porównawcza

6.3.1 Jakość ogólna

Średni wynik Overall Score dla trybu Sequential wyniósł **82.2/100** (średnia z 87.6, 81.6, 77.5), podczas gdy dla trybu Group Chat **69.3/100** (średnia z 55.4, 74.2, 78.3). Tryb Sequential osiągnął wynik wyższy o **12.9 punktu**.

Jednak analiza szczegółowa pokazuje, że różnica ta jest silnie zróżnicowana między symbolami:

- AAPL: Sequential lepszy o **32.2 pkt** (87.6 vs 55.4)
- NVDA: Sequential lepszy o **7.4 pkt** (81.6 vs 74.2)
- GOOGL: Group Chat lepszy o **0.8 pkt** (78.3 vs 77.5)

Wskazuje to, że **efektywność trybu Group Chat jest silnie zależna od kontekstu analizy**, z dramatycznie różnymi wynikami dla różnych spółek.

6.3.2 Structure

Wymiar Structure wykazał wysoką jakość w obu trybach:

- Sequential: średnio 95.0/100 (100, 85, 100)
- Group Chat: średnio 96.7/100 (100, 90, 100)

Oba tryby konsekwentnie osiągają pełne pokrycie wszystkich 8 wymaganych sekcji. Group Chat ma tendencję do generowania większej liczby paragrafów (średnio 13 vs 8.3 w Sequential), co wskazuje na bardziej rozdrobnioną narrację typową dla syntezy wypowiedzi wielu agentów.

6.3.3 Data Richness - krytyczna różnica

To wymiar, w którym różnica między trybami jest **najbardziej dramatyczna**:

- Sequential: średnio **76.3/100** (100, 78.5, 50.5)
- Group Chat: średnio **45.8/100** (27.0, 62.0, 48.5)
- Różnica: **-30.5 punktu**

Szczegółowa analiza liczb:

- **Total numbers:** Sequential 19.3 vs Group Chat 2.7 (7× mniej)
- **Financial metrics:** Sequential 15.0 vs Group Chat 10.3 (1.5× mniej)
- **Citations:** Sequential 3.7 vs Group Chat 2.0 (1.8× mniej)

Najbardziej problematyczny jest przypadek AAPL Group Chat, gdzie wykryto **0 liczb** - raport zawierał jedynie *nazwy* metryk bez jakichkolwiek konkretnych wartości liczbowych.

Możliwe przyczyny degradacji Data Richness w Group Chat:

1. **Kompresja informacji w fazie syntezy** - agenci Trust, Sceptic i Leader skupiają się na agregacji argumentów, pomijając konkretne dane liczbowe
2. **Krótsze raporty** - Group Chat generuje średnio 361 słów vs 634 słów w Sequential (43% krócej), co może skutkować utratą szczegółów
3. **Brak bezpośredniego dostępu do danych źródłowych** - agenci debatowi mogą nie mieć dostępu do surowych danych Yahoo Finance, operując jedynie na syntezie przygotowanej przez agentów specjalistycznych

6.3.4 Professional Sophistication - przewaga Group Chat

To wymiar, w którym Group Chat konsekwentnie przewyższa Sequential:

- Sequential: średnio **77.0/100** (71.8, 78.1, 81.1)
- Group Chat: średnio **91.8/100** (93.2, 83.2, 99.1)
- Różnica: **+14.8 punktu**

Flesch scores (niższy = bardziej akademicki):

- Sequential: średnio 23.0 (28.2, 21.9, 18.9)
- Group Chat: średnio 8.2 (6.8, 16.8, 0.9)

Średnia liczba sylab na słowo:

- Sequential: 2.00 (1.95, 2.02, 2.04)
- Group Chat: 2.18 (2.19, 2.07, 2.29)

Raport GOOGL Group Chat osiągnął **najwyższy możliwy poziom** wyrafinowania językowego (Flesch 0.9, Sophistication 99.1), wskazując na ekstremalne rafinowanie języka w procesie wieloagentowej syntezy.

Interpretacja: Proces debaty prowadzi do **wieloetapowej rafinacji języka**, w której kolejni agenci (Trust, Sceptic, Leader) "uszlachetniają" styl wypowiedzi, eliminując prostsze sformułowania na rzecz bardziej złożonych, akademickich konstrukcji. Efekt ten jest szczególnie widoczny w GOOGL (Flesch 0.9) i AAPL (Flesch 6.8).

6.3.5 Actionability - niekonsekwentna jakość Group Chat

Wymiar Actionability wykazuje **największą wariancję** w Group Chat:

- Sequential: średnio **100.0/100** (wszystkie maksymalne)
- Group Chat: średnio **48.3/100** (0, 55, 90)
- Różnica: **-51.7 punktu**

Sequential **konsekwentnie** osiąga maksymalny wynik 100/100 dla wszystkich symboli, co potwierdza stabilność generowania jasnych rekomendacji z price target i time horizon.

Group Chat wykazuje **ekstremalną niestabilność**:

- AAPL: 0/100 (brak price target i time horizon)
- NVDA: 55/100 (brak time horizon)
- GOOGL: 90/100 (wszystkie elementy obecne)

Interpretacja: Proces debaty może prowadzić do **utraty konkretnych parametrów** w fazie syntezy końcowej. Agenci Trust i Sceptic mogą kwestionować konkretne wartości price target, co prowadzi do ich usunięcia z finalnego raportu w imię "obiektywizmu" lub "ostrożności".

6.3.6 Sentiment Balance - mieszane wyniki

- Sequential: średnio **62.7/100** (74.4, 35.6, 78.0)
- Group Chat: średnio **76.2/100** (56.2, 79.1, 93.3)
- Różnica: **+13.5 punktu dla Group Chat**

Group Chat osiąga **lepszy balans sentymentu** dzięki obecności Sceptic Agent, który wprowadza perspektywę krytyczną, równoważąc pozytywne argumenty Trust Agent. Najlepszy wynik osiągnął GOOGL Group Chat (93.3, B=0.067 - prawie idealny balans).

Sequential wykazuje większą **wariancję** (35.6-78.0), szczególnie problematyczny jest NVDA Sequential (35.6, B=0.644 - silnie pozytywny bias).

6.3.7 Czas wykonania

- Sequential: średnio **117.6s** (125.4, 99.3, 128.1)
- Group Chat: średnio **524.8s** (584.9, 645.7, 343.9)
- Różnica: Group Chat **4.46× wolniejszy**

Ratio dla poszczególnych symboli:

- AAPL: 4.66× (584.9s vs 125.4s)
- NVDA: 6.50× (645.7s vs 99.3s) - największa różnica
- GOOGL: 2.68× (343.9s vs 128.1s) - najmniejsza różnica

Trade-off między czasem a jakością jest **niekorzystny** dla Group Chat: mimo 4.5× dłuższego czasu wykonania, średni wynik Overall Score jest **niższy** o 12.9 punktu.

6.4 Wnioski i rekomendacje

6.4.1 Tryb Sequential - zalecany dla większości zastosowań

Tryb Sequential okazał się **bardziej efektywny** w kontekście:

- Kompletności danych liczbowych (Data Richness: 76.3 vs 45.8)
- Stabilności rekomendacji (Actionability: 100.0 vs 48.3)
- Ogólnej jakości raportu (Overall: 82.2 vs 69.3)
- Efektywności czasowej (117.6s vs 524.8s)

Zalecenia zastosowania:

- Raporty inwestycyjne wymagające konkretnych danych liczbowych
- Scenariusze wymagające szybkiego generowania raportów
- Analizy dla klientów detalicznych oczekujących jasnych parametrów (price target, time horizon)

6.4.2 Tryb Group Chat - niszowe zastosowania

Tryb Group Chat wykazuje przewagę w:

- Profesjonalizmie językowym (Sophistication: 91.8 vs 77.0)
- Balansie sentymentu (Sentiment: 76.2 vs 62.7)

Ale ma **krytyczne wady**:

- Dramatyczny spadek Data Richness (7× mniej liczb)
- Niestabilność Actionability (0-90/100)
- 4.5× dłuższy czas wykonania

Zalecenia zastosowania:

- Raporty dla instytucji akademickich wymagających najwyższego poziomu formalizmu językowego
- Analizy gdzie balans perspektyw (bull/bear) jest priorytetem nad konkretnymi danymi
- Scenariusze gdzie czas wykonania nie jest krytyczny

Warunek konieczny: Wymaga poprawy mechanizmu ekstrakcji danych liczbowych w fazie debatowej - obecnie utrata 30.5 punktu Data Richness jest **nieakceptowalna** dla profesjonalnych raportów inwestycyjnych.

6.4.3 Podsumowanie ostateczne

Eksperymenty wykazały, że **tryb Sequential jest obecnie lepszym wyborem** dla generowania profesjonalnych raportów inwestycyjnych, osiągając:

- Wyższy wynik Overall Score (82.2 vs 69.3)
- Konsekwentnie wysoką jakość wszystkich wymiarów
- 4.5× szybsze wykonanie

Tryb Group Chat, mimo teoretycznych zalet architektury debatowej, **nie spełnia obecnie wymagań** profesjonalnych raportów inwestycyjnych ze względu na dramatyczny spadek Data Richness oraz niestabilność Actionability. Wymaga znaczących usprawnień przed potencjalnym wdrożeniem produkcyjnym.

Jedynym scenariuszem, gdzie Group Chat może być preferowany, są **raporty akademickie** wymagające najwyższego poziomu wyrafinowania językowego (Sophistication 90+) i idealnego balansu sentymentu, gdzie konkretne dane liczbowe są drugorzędne wobec głębokości analizy argumentacyjnej.

Literatura

[AMA05] Paul Asquith, Michael B Mikhail, and Andrea S Au. Information content of equity analyst reports. *Journal of Financial Economics*, 75(2):245–282, 2005.

[CCZ+25] Xin Cai, Yifan Chen, Qi Zhang, Yuxuan Liu, Xue Wang, Ying Chen, and Yiming Li. Findebate: A multi-agent debate framework for institutional-level financial analysis. *arXiv preprint*, arXiv:2509.17395, 2025.

[CFA20] CFA Institute. *Standards of Practice Handbook*. CFA Institute, Charlottesville, VA, 11th edition, 2020.

[CFA23] CFA Institute. *CFA Program Curriculum Level I, Volume 3: Financial Statement Analysis*. CFA Institute, Charlottesville, VA, 2023.

[Fle48] Rudolf Flesch. A new readability yardstick. *Journal of Applied Psychology*, 32(3):221–233, 1948.

[GCW+24] Taicheng Guo, Xiuying Chen, Yaqi Wang, Ruidi Chang, Shichao Pei, Nitesh V. Chawla, Olaf Wiest, and Xiangliang Zhang. Large language model based multi-agents: A survey of progress and challenges, 2024.

[Inv25] Investopedia Editors. Financial term dictionary. https://www.investopedia.com/financial-term-dictionary-4769738, 2025. Accessed: 2026-01-05.

[KMN25] Alex Kim, Maximilian Muhn, and Valeri Nikolaev. Financial statement analysis with large language models, 2025.

[LLM11] Reuven Lehavy, Feng Li, and Kenneth Merkley. The effect of annual report readability on analyst following and the properties of their earnings forecasts. *The Accounting Review*, 86(3):1087–1115, 2011.

[LM11] Tim Loughran and Bill McDonald. When is a liability not a liability? textual analysis, dictionaries, and 10-ks. *The Journal of Finance*, 66(1):35–65, 2011.

[LM16] Tim Loughran and Bill McDonald. Textual analysis in accounting and finance: A survey. *Journal of Accounting Research*, 54(4):1187–1230, 2016.

[SCP+25] Supriyo Satapathy, Dwaipayan Chowdhury, Goutam Panda, Neha Chinnappa, and Siddhartha Chawla. Multi-agent llms for financial report analysis. In *Proceedings of the 2nd Workshop on Financial Technology and Natural Language Processing (FinNLP) at EMNLP 2025*. Association for Computational Linguistics, 2025.

[XPM+25] Tao Xu, Zhe Piao, Tadashi Mukai, Yuri Murayama, and Kiyoshi Izumi. Emulating fundamental analysts: Analytical stage-based multi-agent framework enhanced with expert guidance and preference-anchored likelihood adjustment. *Intelligent Systems with Applications*, 26:200496, 2025.

[XSLW25] Yijia Xiao, Edward Sun, Di Luo, and Wei Wang. Tradingagents: Multi-agents llm financial trading framework, 2025.